Deep Learning School

Transformer architecture

Encoder block

План занятия

- Идея архитектуры Transformer для машинного перевода
- Устройство Transformer Encoder
- Устройство Transformer Decoder
- QKV Attention

В этом видео

- **Идея архитектуры Transformer**
- **Устройство Transformer Encoder**
- Устройство Transformer Decoder
- QKV Attention

Недостатки RNN

Encoder на основе RNN очень медленный:

- Forward pass работает медленно, так как обрабатывает входящие токены последовательно;
- Backward pass работает медленно, так как происходит распространение градиентов сквозь время;

У RNN возникают проблемы во время обучения:

- Затухание/взрыв градиентов;
- Плохая утилизация GPU

Недостатки RNN

Нужны ли нам все еще RNN?

Мы использовать RNN для решения задачи машинного перевода, потому что их структура позволяет собирать информацию из входной последовательности и передавать ее декодеру.

Но сейчас у нас есть механизм Attention, который позволяет декодеру в любой момент времени “смотреть” на любую часть исходного предложения.

Идея Transformer

Transformer — архитектура, основа которой — механизм Attention.

У Transformer нет RNN-слоев.

Идея Transformer

Transformer впервые предложили в 2017 году в статье от Google “**Attention is all you need**”

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

Идея Transformer

У Transformer архитектура тоже имеет тип Encoder-Decoder

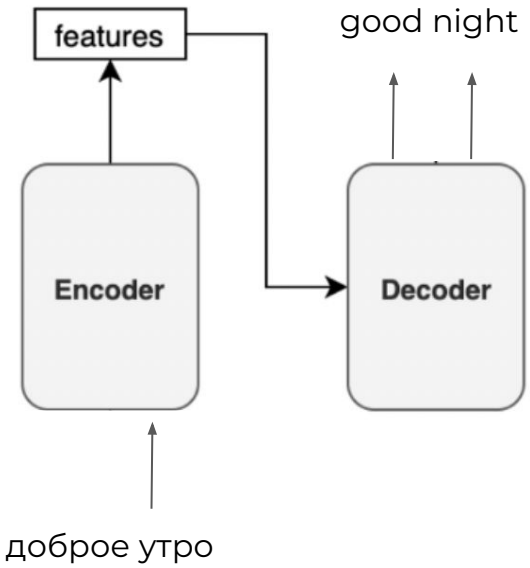

Transformer Encoder

Encoder обрабатывает токены входящей последовательности ***параллельно***

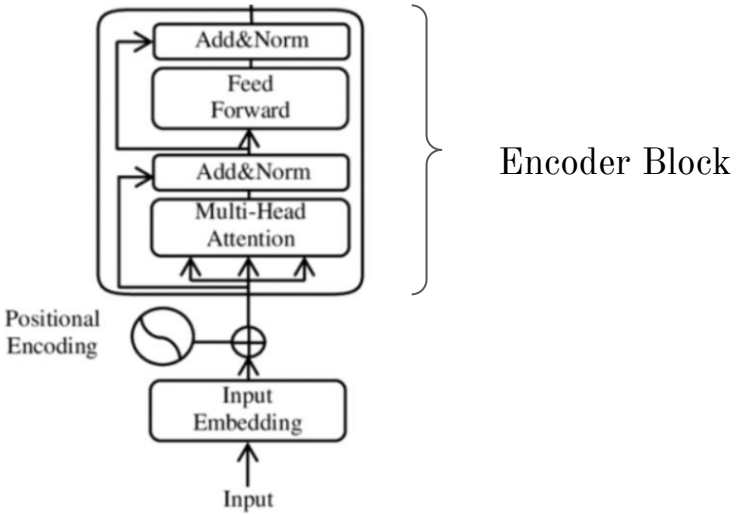

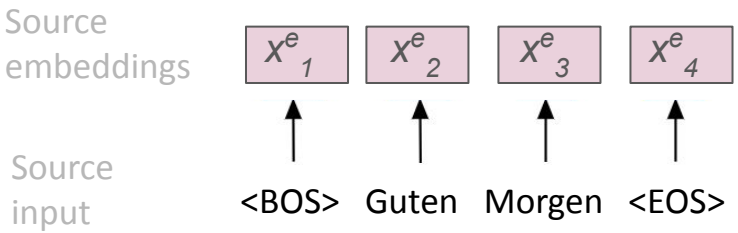
Source embeddings
x^e_1
x^e_2
x^e_3
x^e_4
Source input
<BOS>
Guten
Morgen
<EOS>

Слой self-attention вычисляет дополнительную информацию для эмбеддинга каждого токена на основе его контекста (т.е. эмбеддингов всех других токенов)

“Sport is good, it helps a lot”

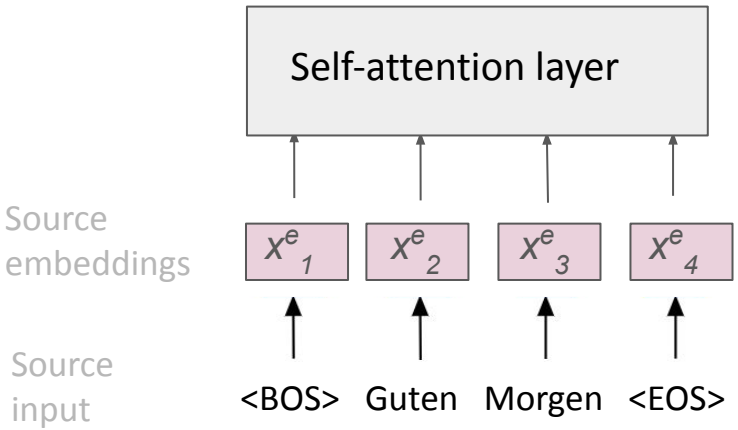

$$a_1^e = \sum_{i=1}^{4} w_{1i} x_i^e$$

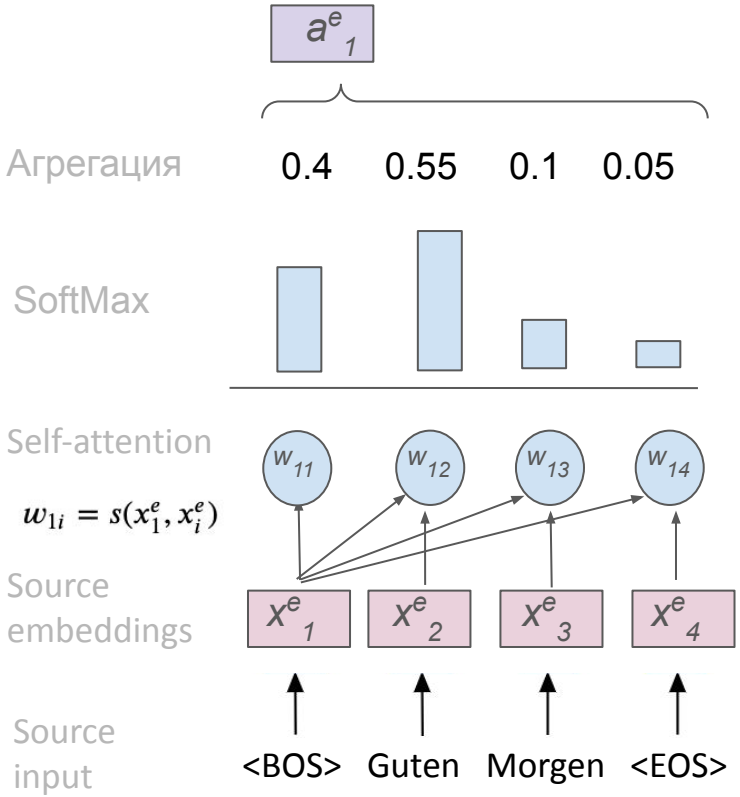

$$a_2^e = \sum_{i=1}^{4} w_{2i} x_i^e$$

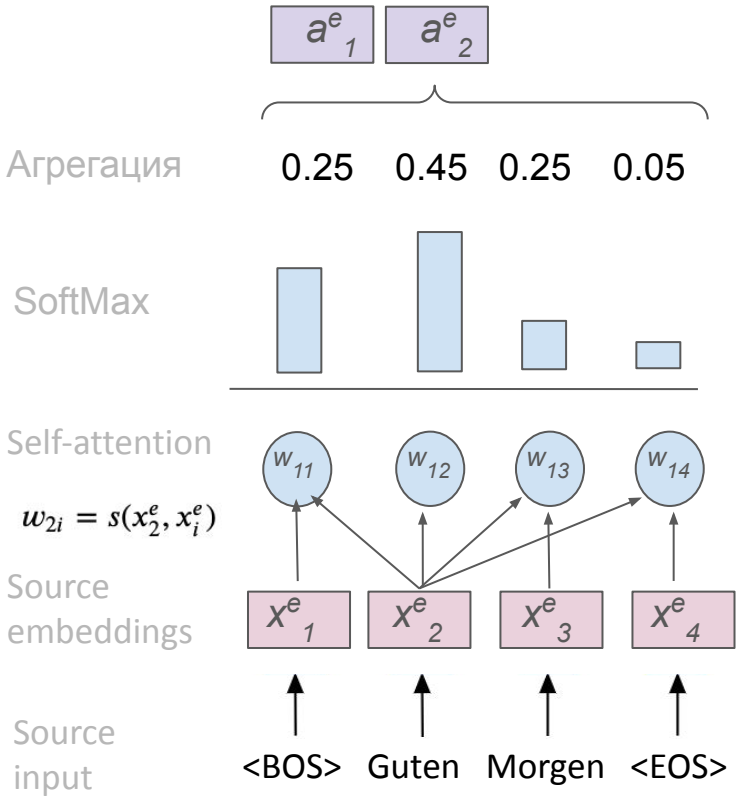

$$a_3^e = \sum_{i=1}^{4} w_{3i} x_i^e$$

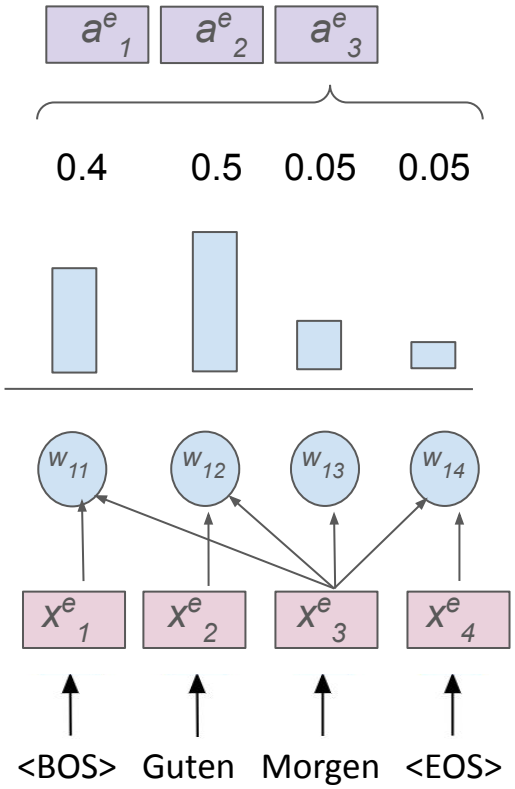

$$a_4^e = \sum_{i=1}^{4} w_{4i} x_i^e$$

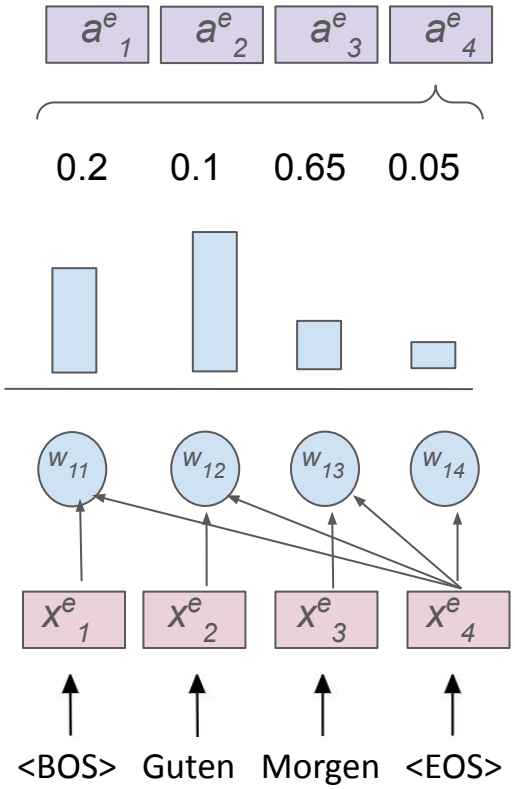

Self-Attention применяется ко всем эмбеддингам параллельно

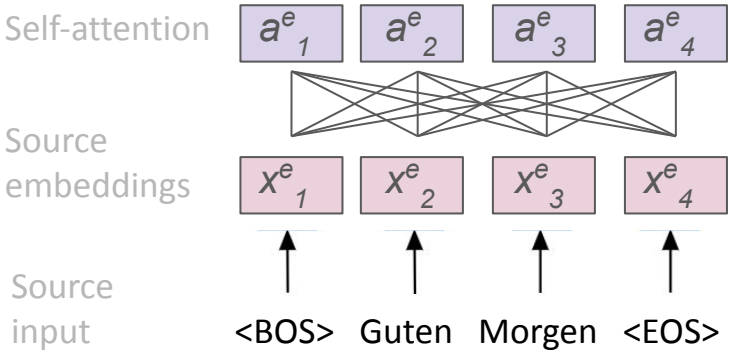

Слой self-attention вычисляет дополнительную информацию для эмбеддинга каждого токена на основе его контекста

“Sport is good, it helps a lot”

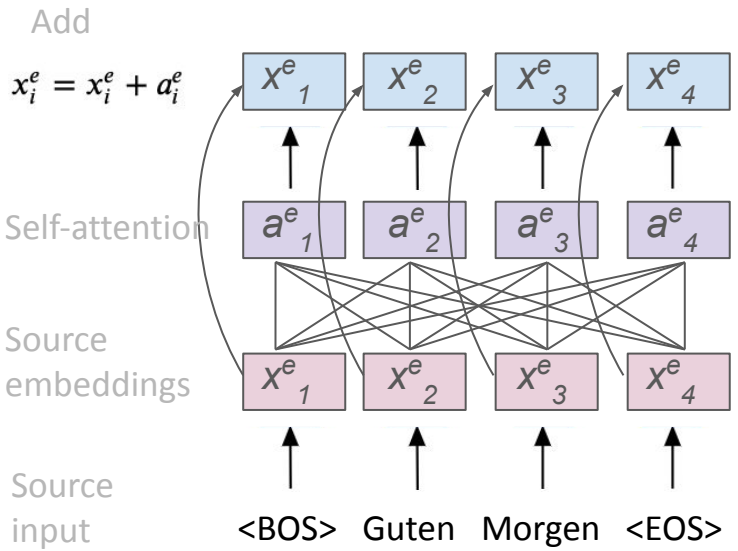

Визуализация весов слоя self-attention

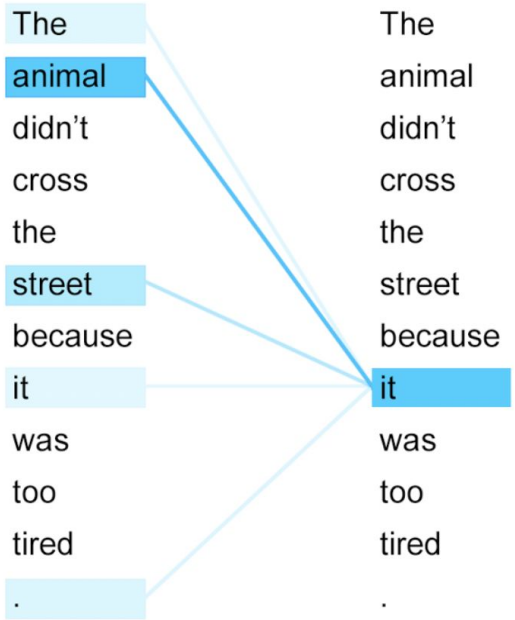

Визуализация весов слоя self-attention

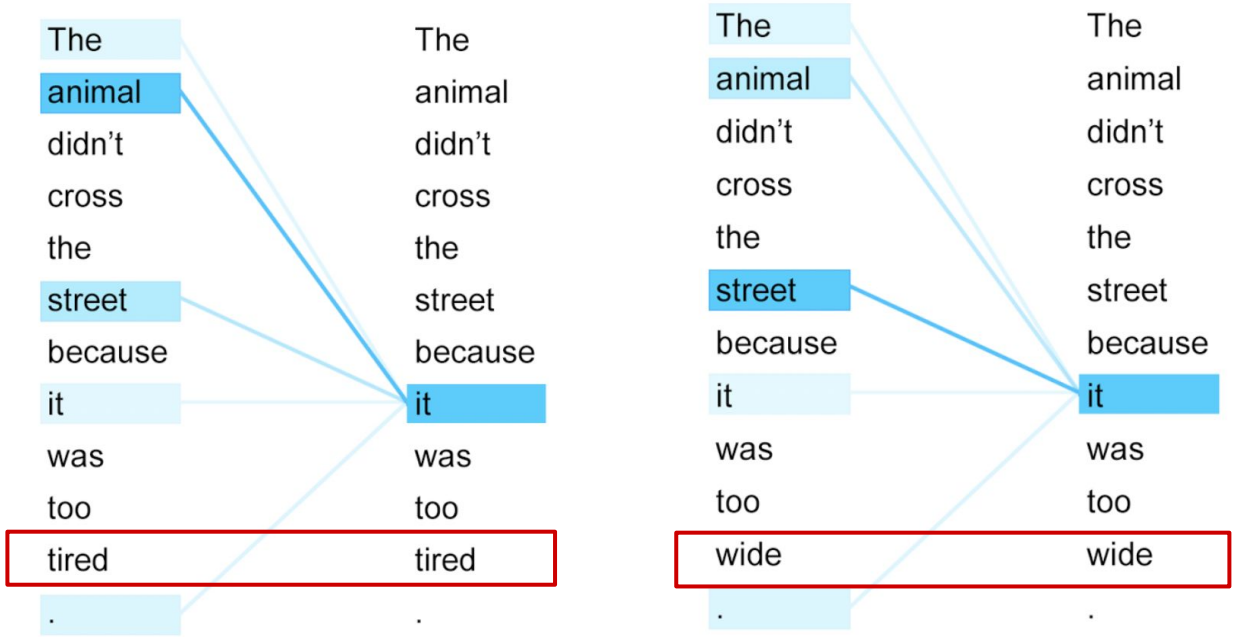

LayerNorm делает так, что выходы слоя всегда будут иметь одинаковые mean и variance.

Это делает обучение сети более стабильным

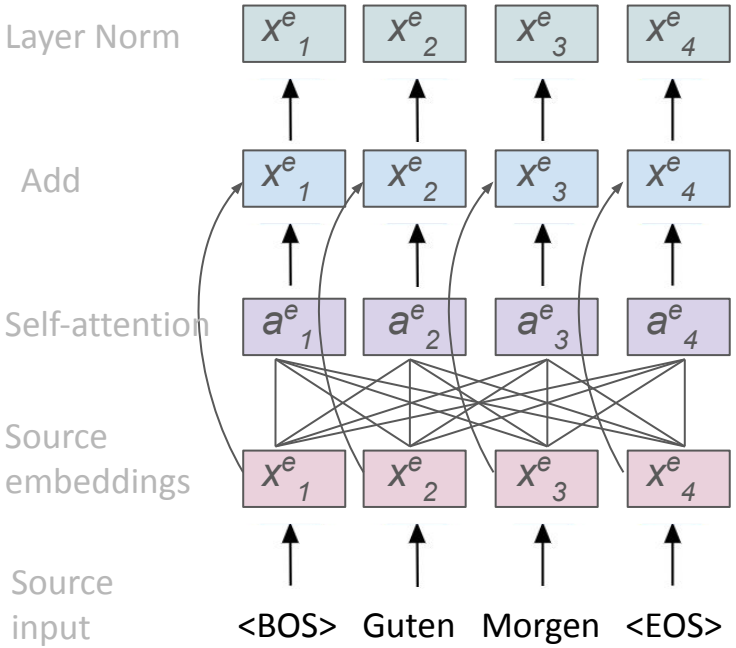

Layer Norm

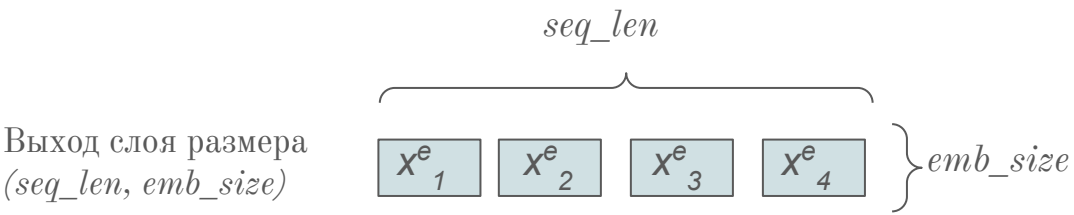

Считаем среднее и стандартное отклонение по всем координатам каждого эмбеддинга x^e_i:

$$\mu_i = \frac{1}{emb\_size} \sum_{j=1}^{emb\_size} x_j^e \qquad \sigma_i = \sqrt{\frac{1}{emb\_size} \sum_{j=1}^{emb\_size} (x_j^e - \mu_i)}$$

$$1 \le i \le seq\_len$$

Layer Norm

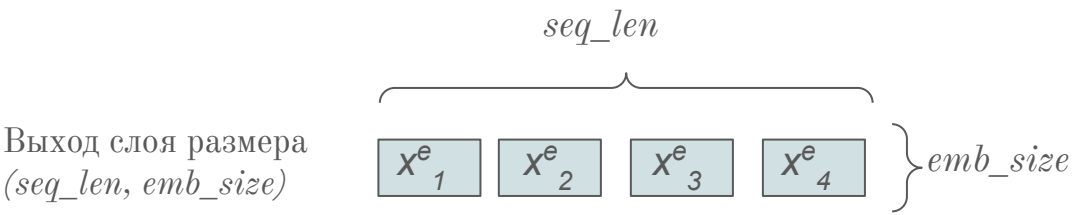

После этого обновляем элементы каждого эмбеддинга x^e_i следующим образом:

$$x_i^e = \frac{x_i^e - \mu_i}{\sigma_i + \epsilon} \cdot \gamma + \beta$$

$$1 \leq i \leq seq\_len$$

Здесь γ и β — обучаемые параметры

Layer Norm

LayerNorm можно лучше понять, если сравнить его с BatchNorm:

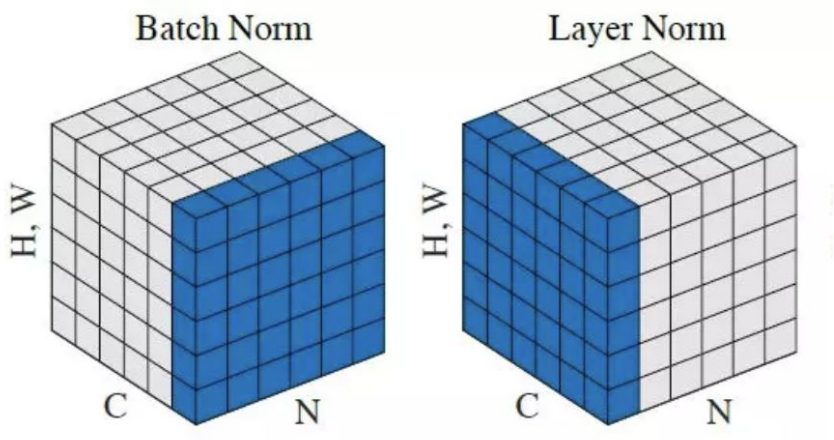

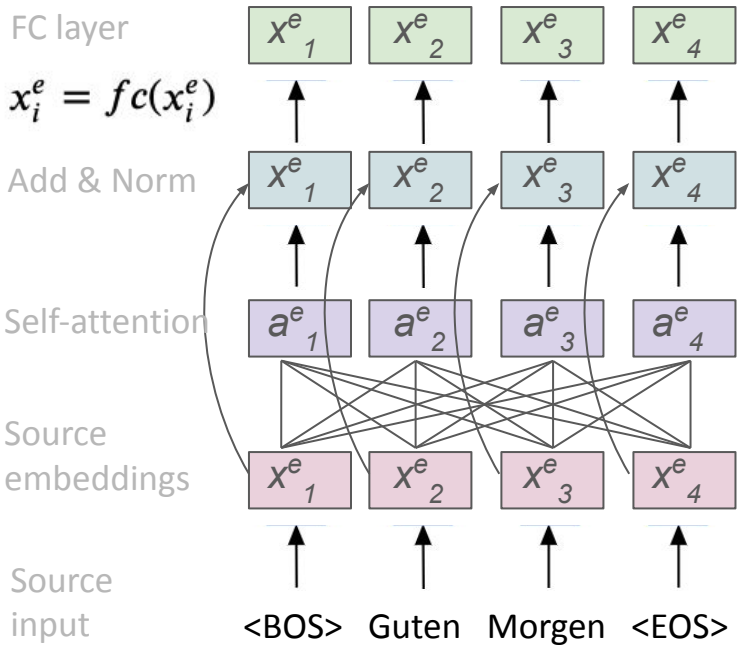
FC layer
$x_i^e = fc(x_i^e)$
Add & Norm
Self-attention
Source embeddings
Source input
x^e_1 x^e_2 x^e_3 x^e_4
x^e_1 x^e_2 x^e_3 x^e_4
a^e_1 a^e_2 a^e_3 a^e_4
x^e_1 x^e_2 x^e_3 x^e_4
<BOS> Guten Morgen <EOS>

Transformer Encoder

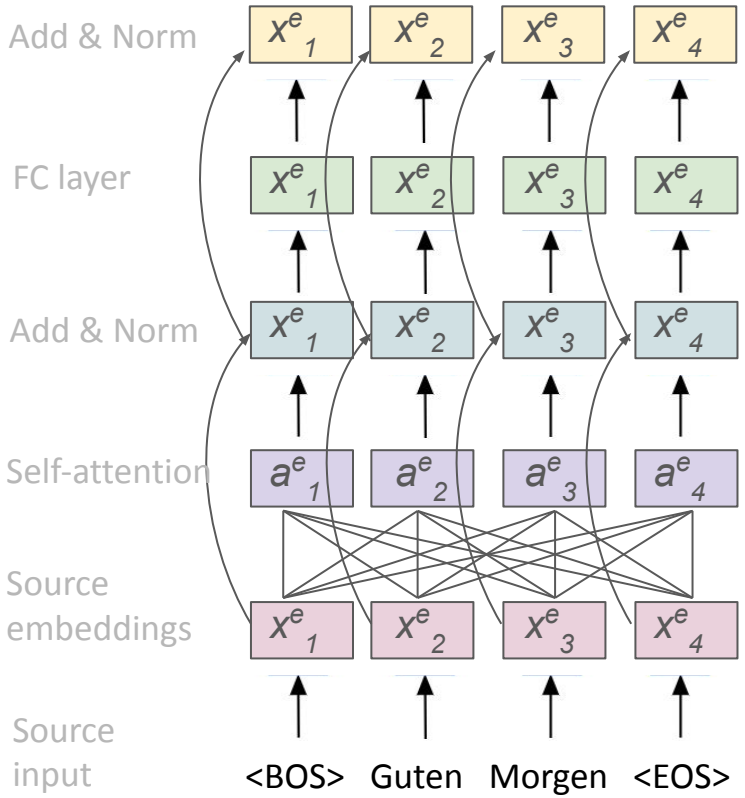

- Результат работы блока Encoder — обновленные эмбеддинги токенов.
- Каждый слой обрабатывает эмбеддинги параллельно
- Каждый слой, кроме слоя self-attention, обрабатывает эмбеддинги независимо
- Transformer Encoder может обрабатывать последовательности разной длины
- Слои в энкодере можно менять местами

Transformer Encoder

Мы почти собрали Encoder.

Чего не хватает:

- *Multi-head* attention
- Positional Encoding

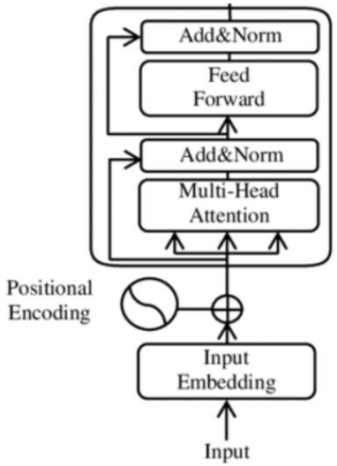

Multi-Head Self-Attention

Между словами в предложении могут быть зависимости разного типа

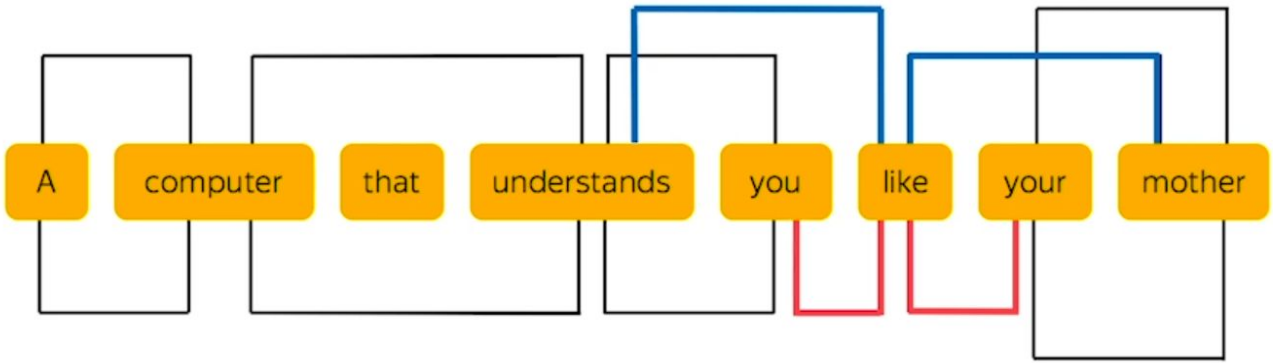

Multi-Head Self-Attention

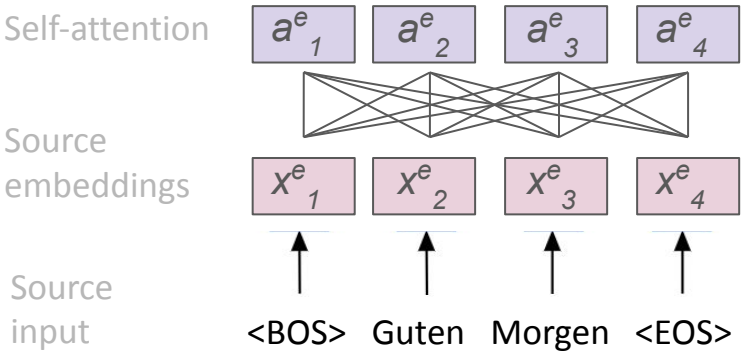

Multi-Head Self-Attention

У всех голов attention различные веса

k — количество голов Attention:

$$w_{ij}^k = s^k(x_i^e, x_j^e)$$

$$a_{ki}^e = \sum_{i=1}^{4} w_{ij}^k x_j^e$$

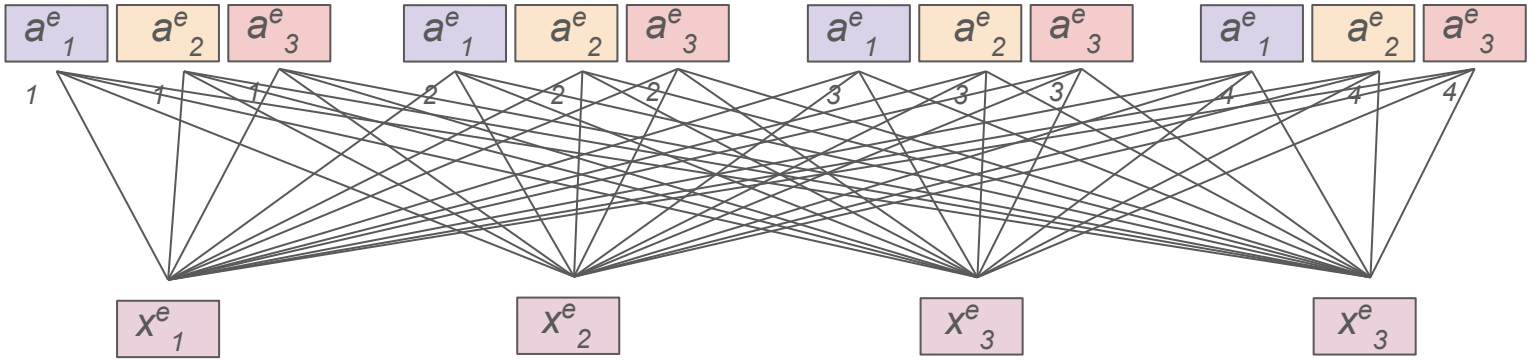

Multi-head Self-attention

Source embeddings

Source input

$$a_i^e = \sigma(W[a_{1i}^e, a_{2i}^e, a_{3i}^e] + b)$$

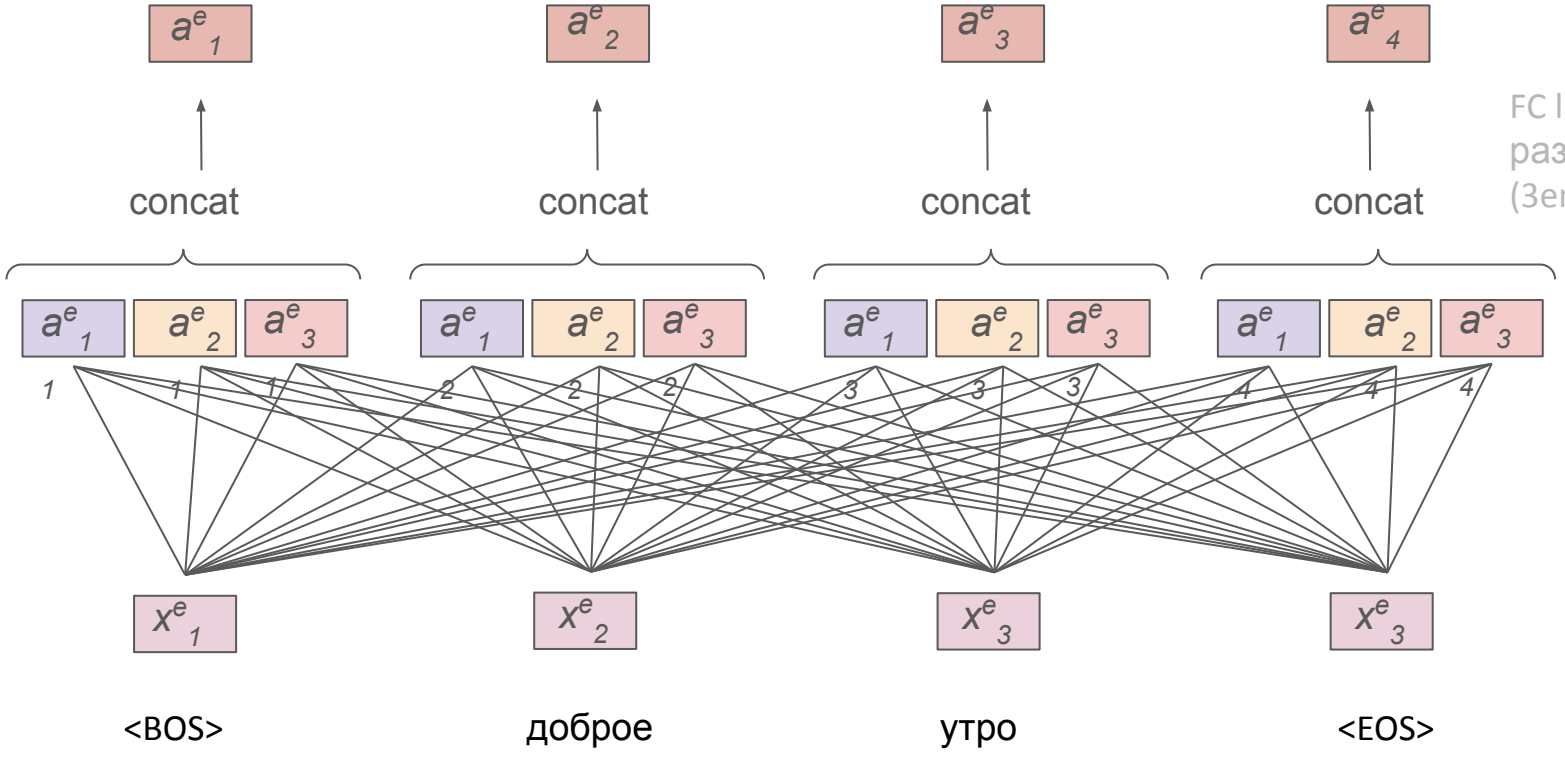

Transformer Encoder

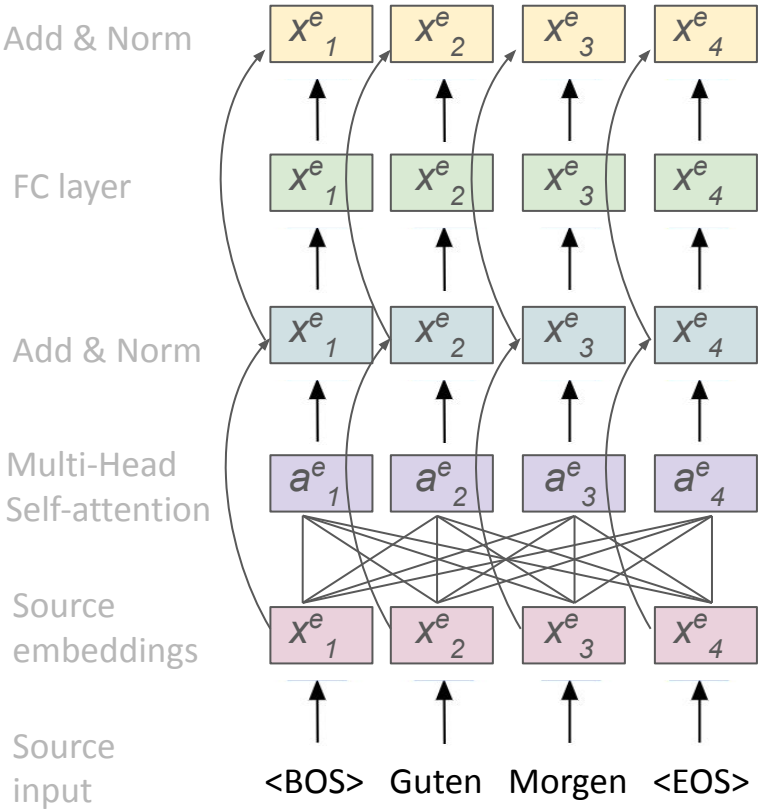

Multi-Head Self-Attention

Разные головы self-attention “обращают внимание”
на разные токены и разную информацию в них

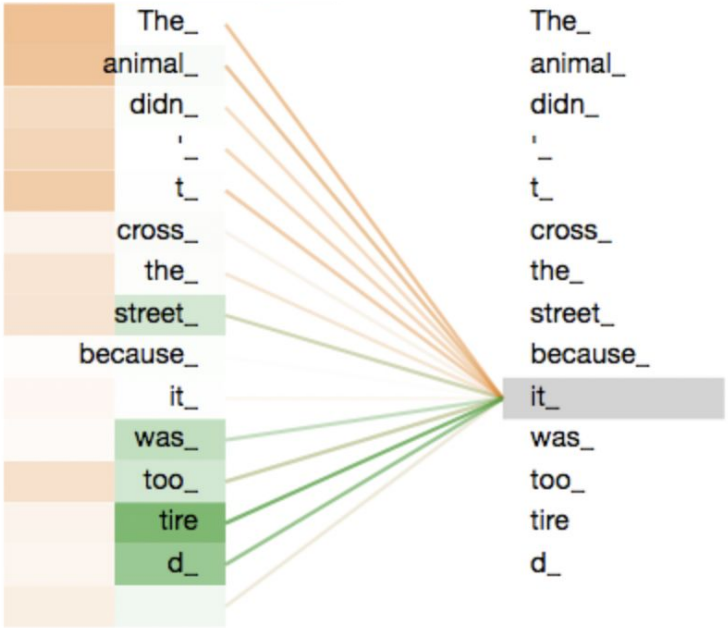

Multi-Head Self-Attention

Разные головы self-attention “обращают внимание”
на разные токены и разную информацию в них

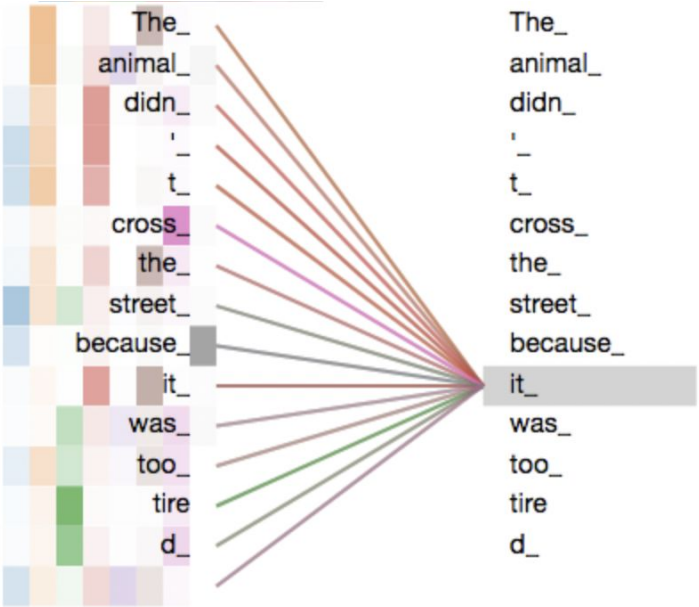

Transformer Encoder

Мы почти собрали Encoder.

Чего не хватает:

- Positional Encoding

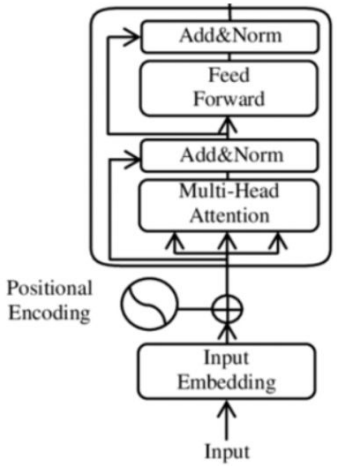

Transformer Encoder

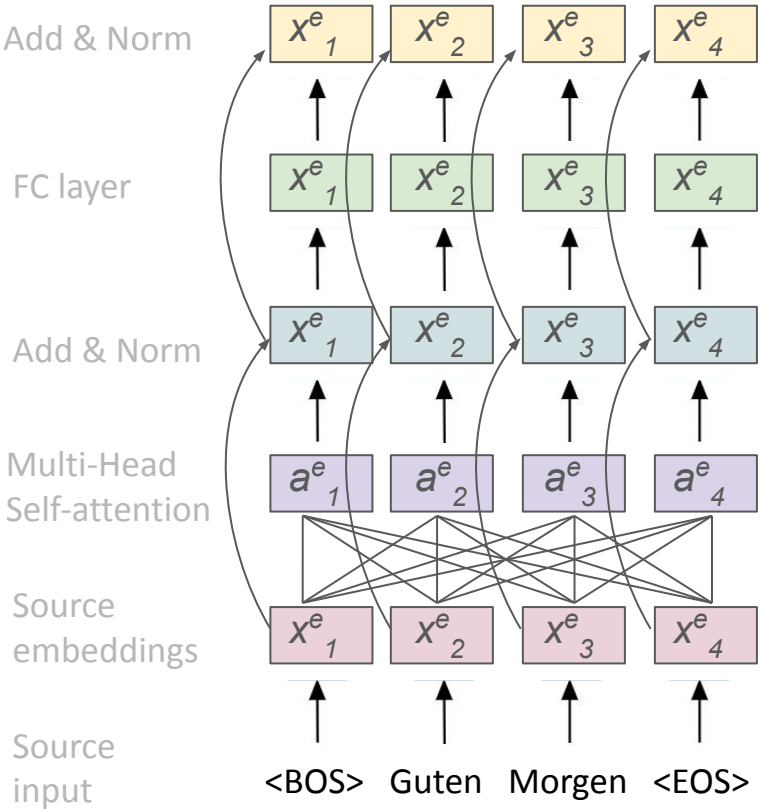

Наша сеть не получает информацию о порядке следования токенов в предложении

Но эта информация важна для понимания смысла эмбеддингов и обновления информации о них:

- cat runs horse
- horse runs cat

Positional Encoding

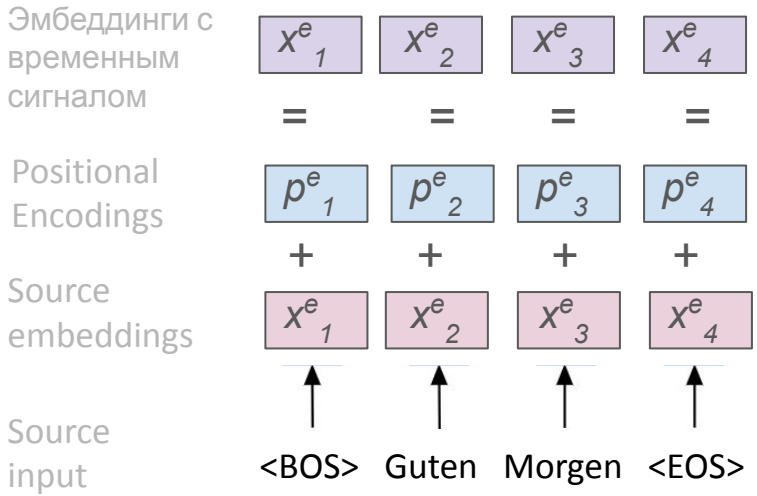

Positional Encoding

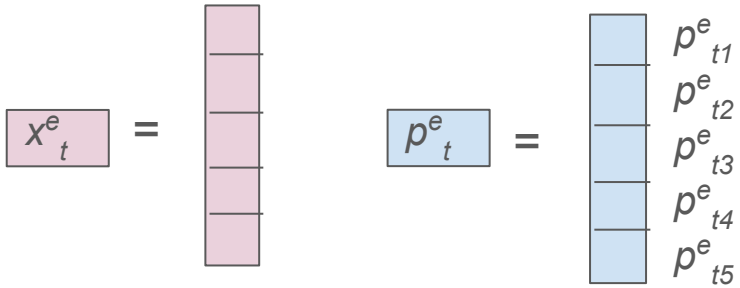

$$p^e_{ti} = \begin{cases} sin\left(\frac{t}{10000^{\frac{2k}{emb\_dim}}}\right), & if\ i = 2k \\ cos\left(\frac{t}{10000^{\frac{2k}{emb\_dim}}}\right), & if\ i = 2k+1 \end{cases}$$

Positional Encoding

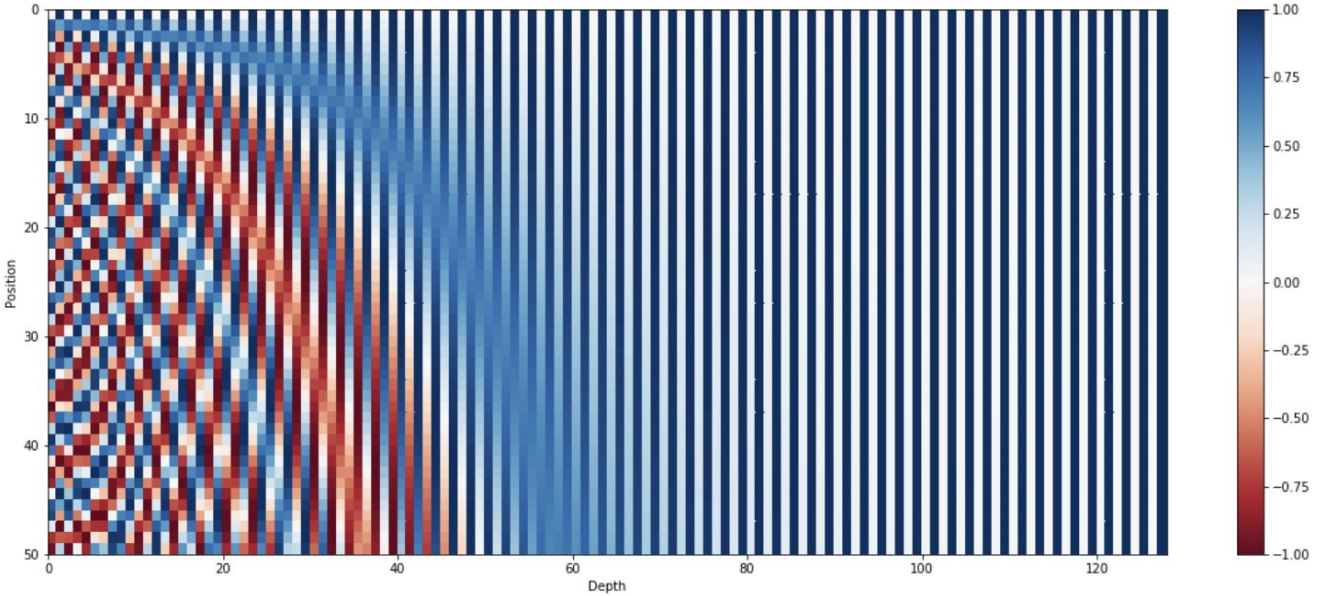

Figure 2 - The 128-dimensional positonal encoding for a sentence with the maximum lenght of 50. Each row represents the embedding vector $\overrightarrow{p_t}$

Positional Encoding

Почему функция positional encoding именно такая:

In this work, we use sine and cosine functions of different frequencies:

$$PE_{(pos,2i)} = sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos,2i+1)} = cos(pos/10000^{2i/d_{\text{model}}})$$

where pos is the position and i is the dimension. That is, each dimension of the positional encoding corresponds to a sinusoid. The wavelengths form a geometric progression from 2π to $10000 \cdot 2\pi$. We chose this function because we hypothesized it would allow the model to easily learn to attend by relative positions, since for any fixed offset k, PE_{pos+k} can be represented as a linear function of PE_{pos}.

https://arxiv.org/pdf/1706.03762.pdf

Transformer Encoder

Ура, мы собрали Encoder!

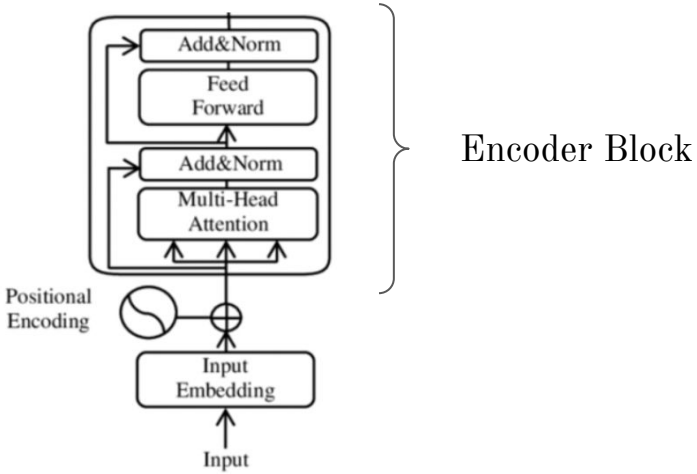

Transformer Encoder

У Encoder могут быть несколько последовательно соединенных блоков

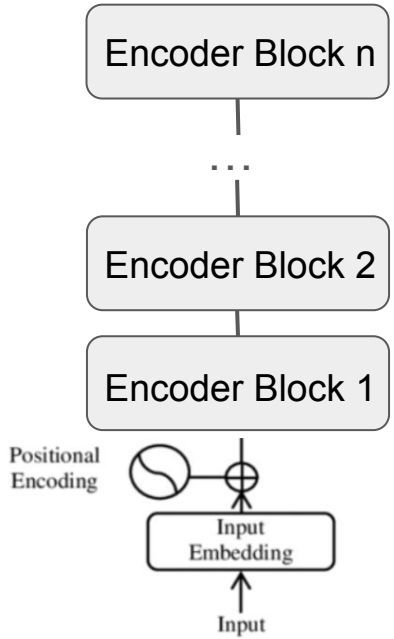

Transformer

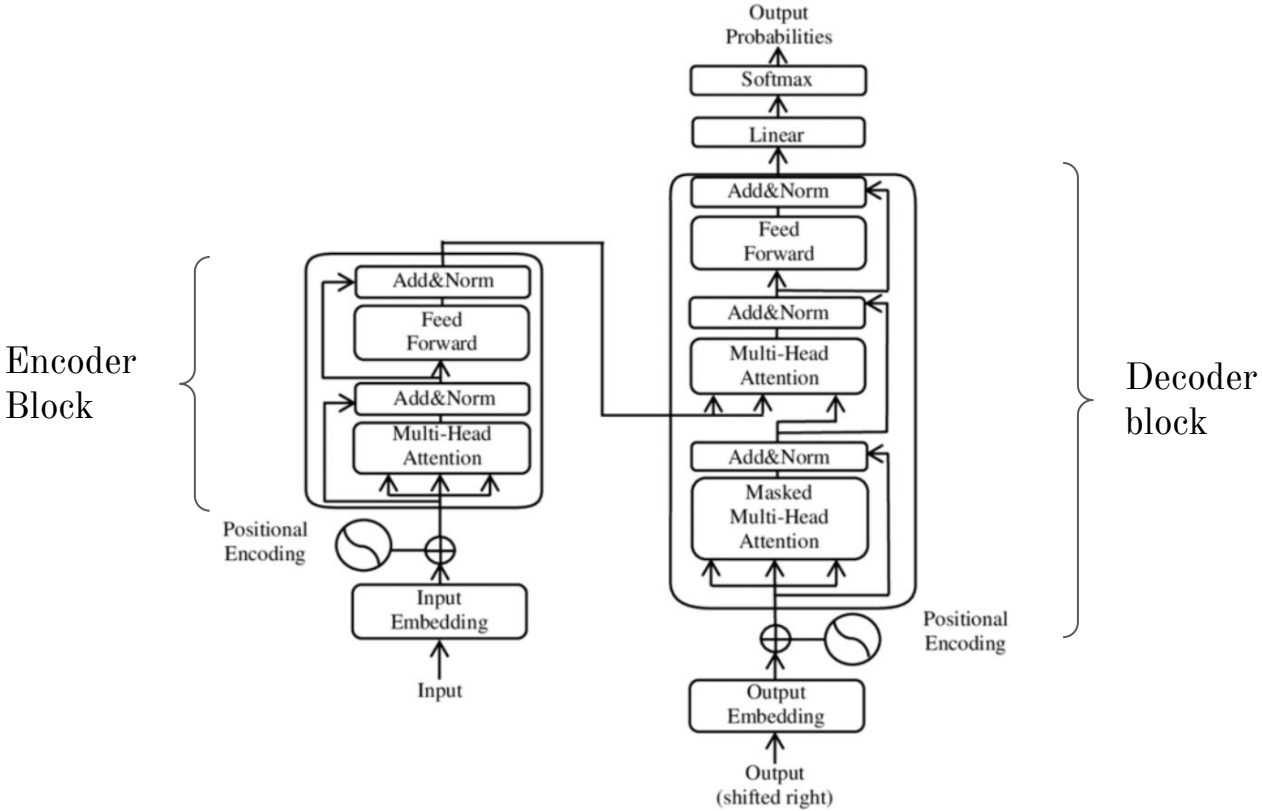

Итоги видео

В этом видео мы:

- Обсудили идею устройства архитектуры Transformer;
- Детально разобрали устройство encoder блока Transformer;
- Познакомились с такими вещами, как:
  - Self-attention;
  - Multi-head Attention;
  - Positional Encodings

Deep Learning School

Transformer architecture

Decoder block

В этом видео

- Идея архитектуры Transformer
- Устройство Transformer Encoder
- **Устройство Transformer Decoder**
- **QKV Attention**

Transformer

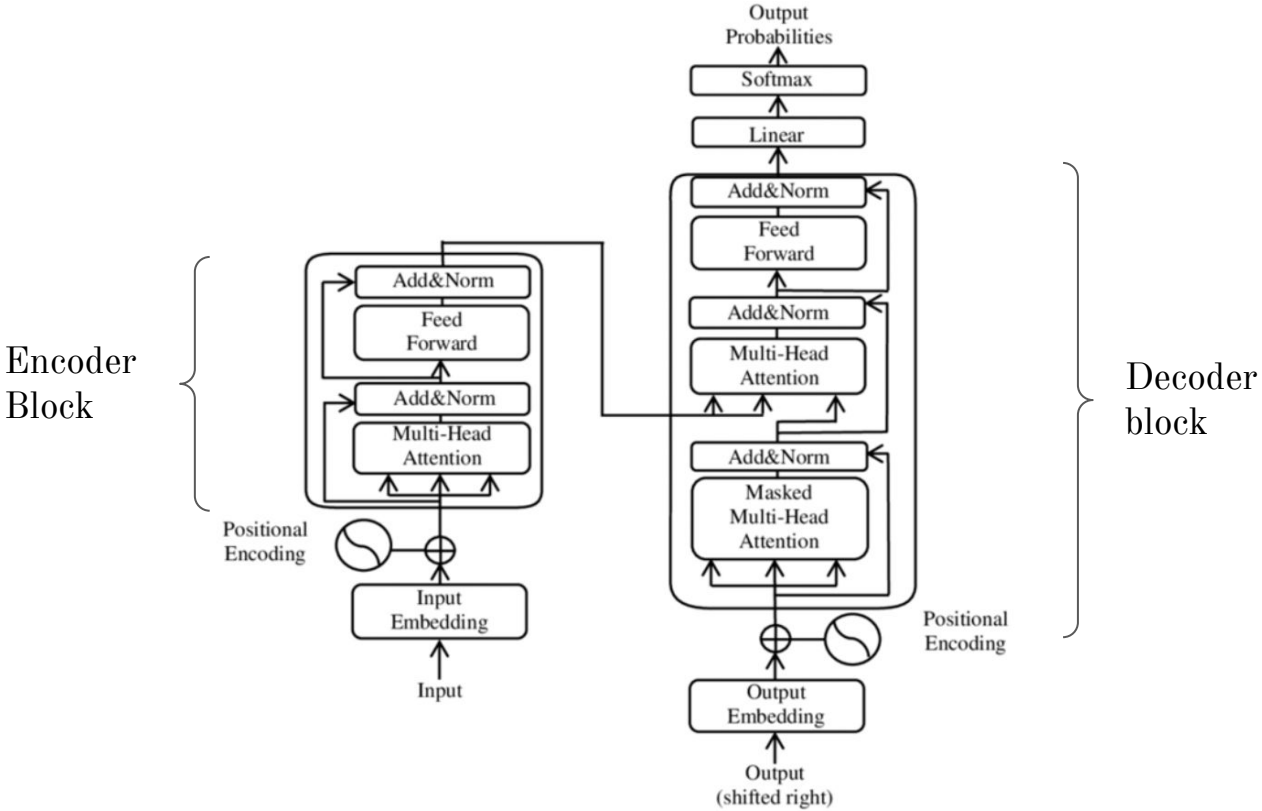

Выходы decoder block (обновленные эмбеддинги)

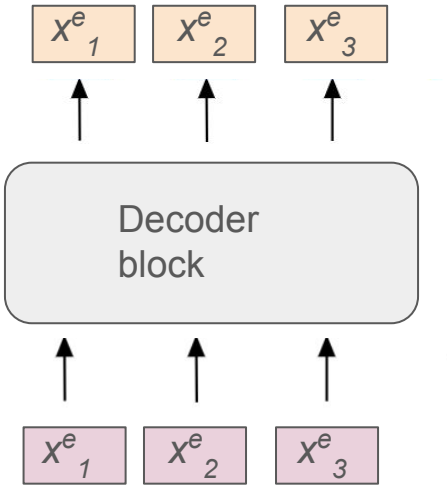

Decoder block inputs

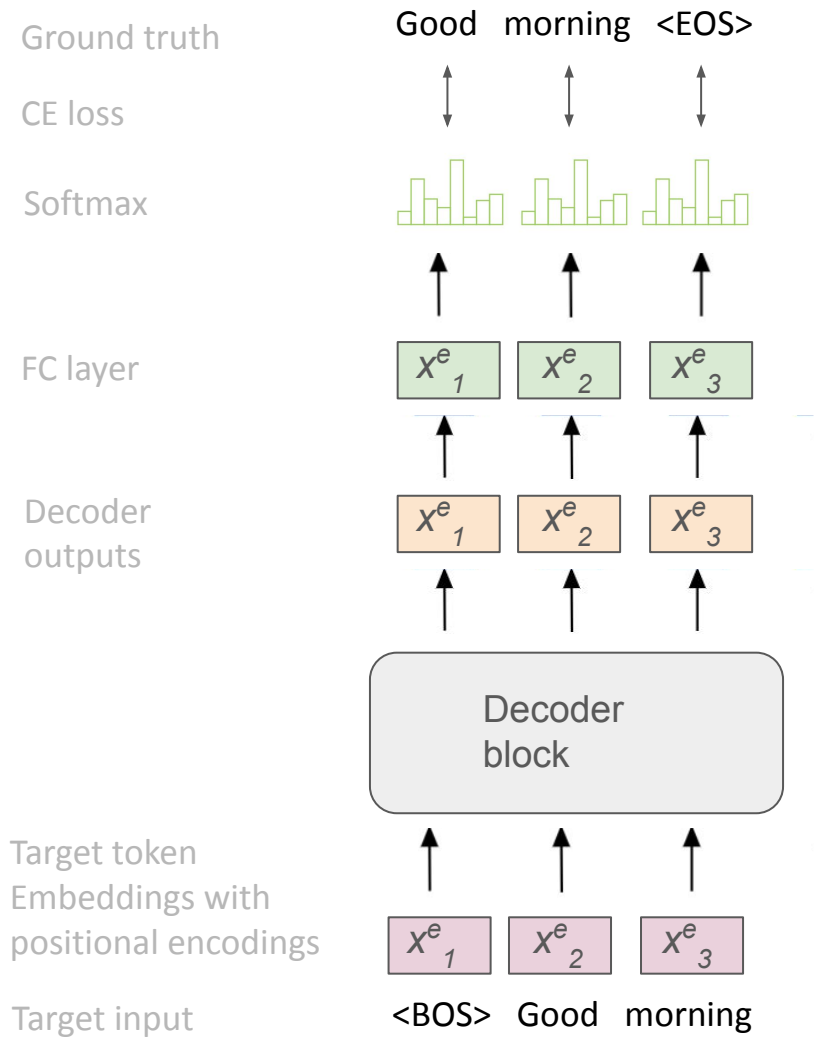

Во время обучения мы можем подать на вход декодеру сразу все токены target предложения

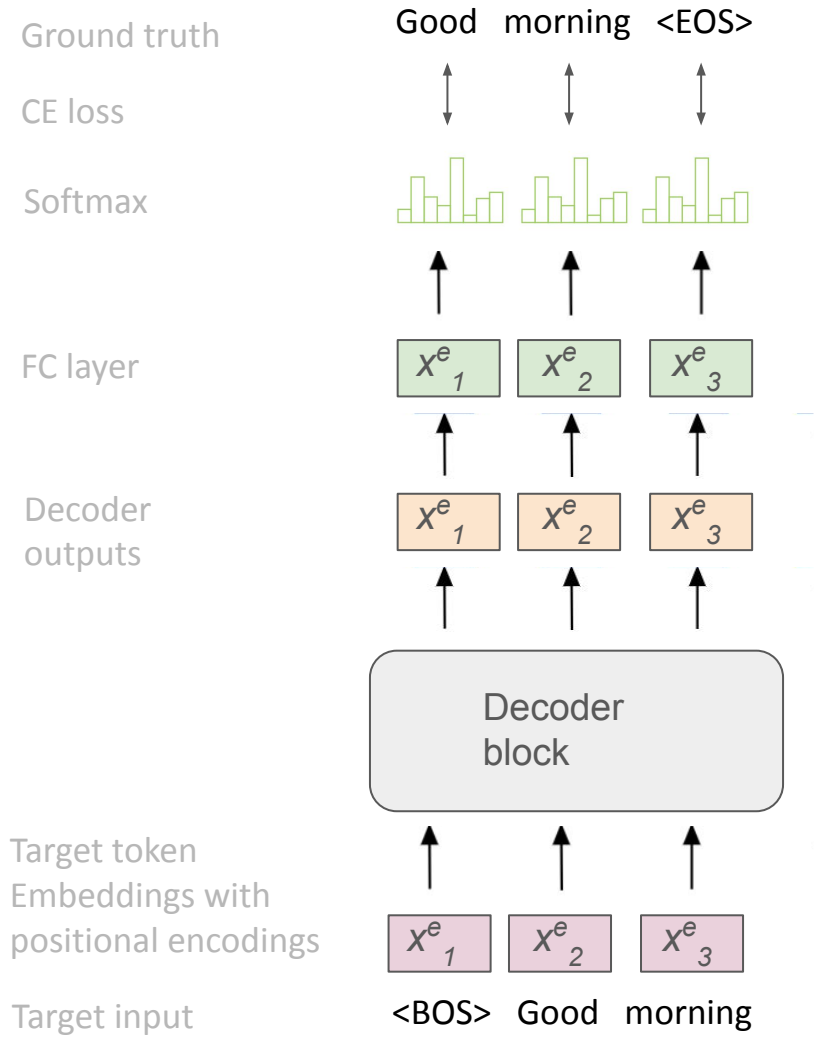

Во время обучения мы можем подать на вход декодеру сразу все токены target предложения

Во время инференса decoder генерирует выходную последовательности ***авторерессивно***

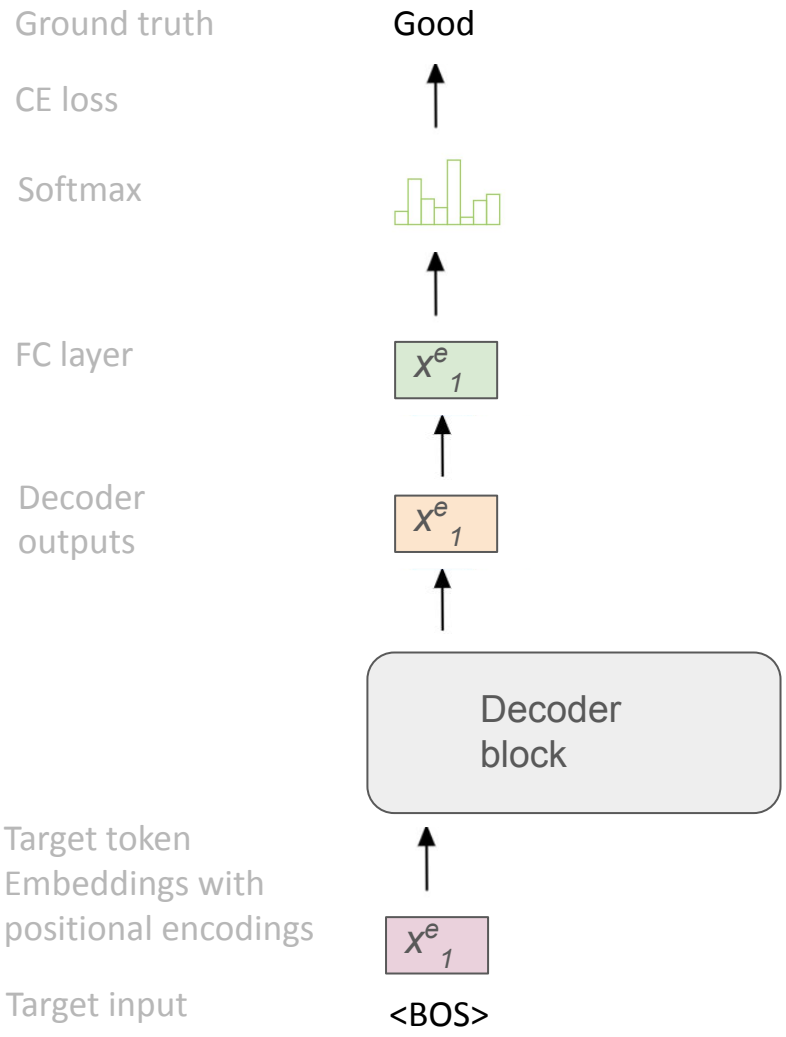

Во время инференса decoder генерирует выходную последовательности ***авторерессивно***

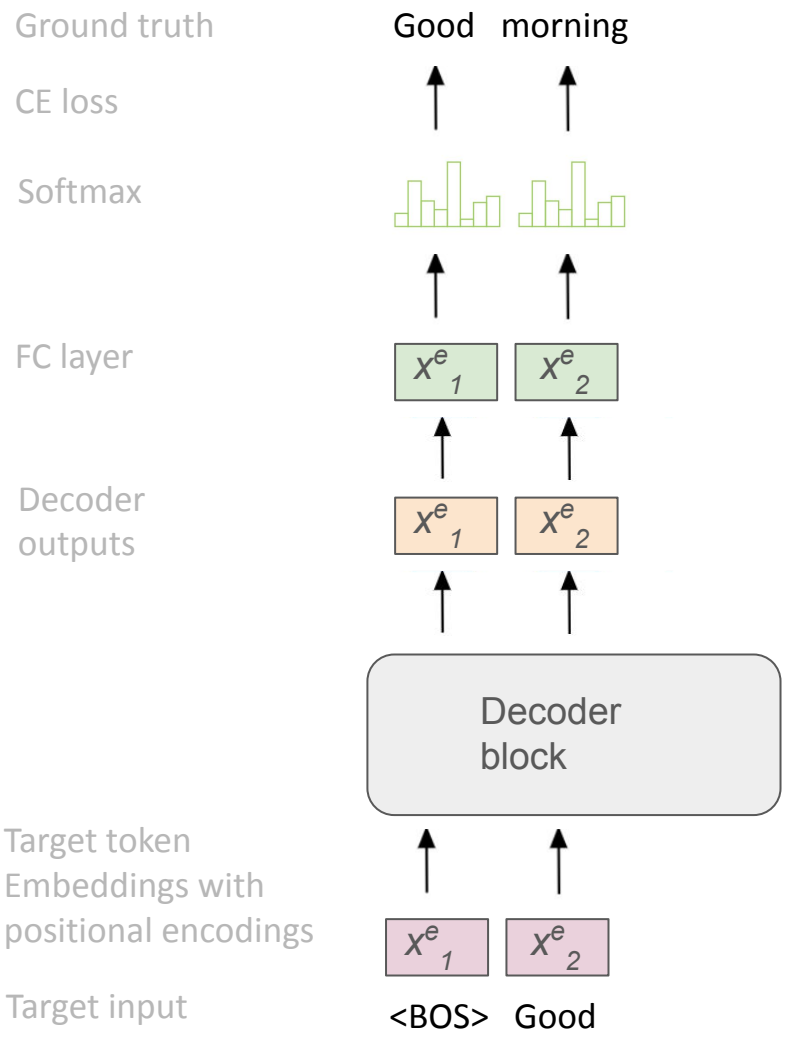

Во время инференса decoder генерирует выходную последовательности ***авторерессивно***

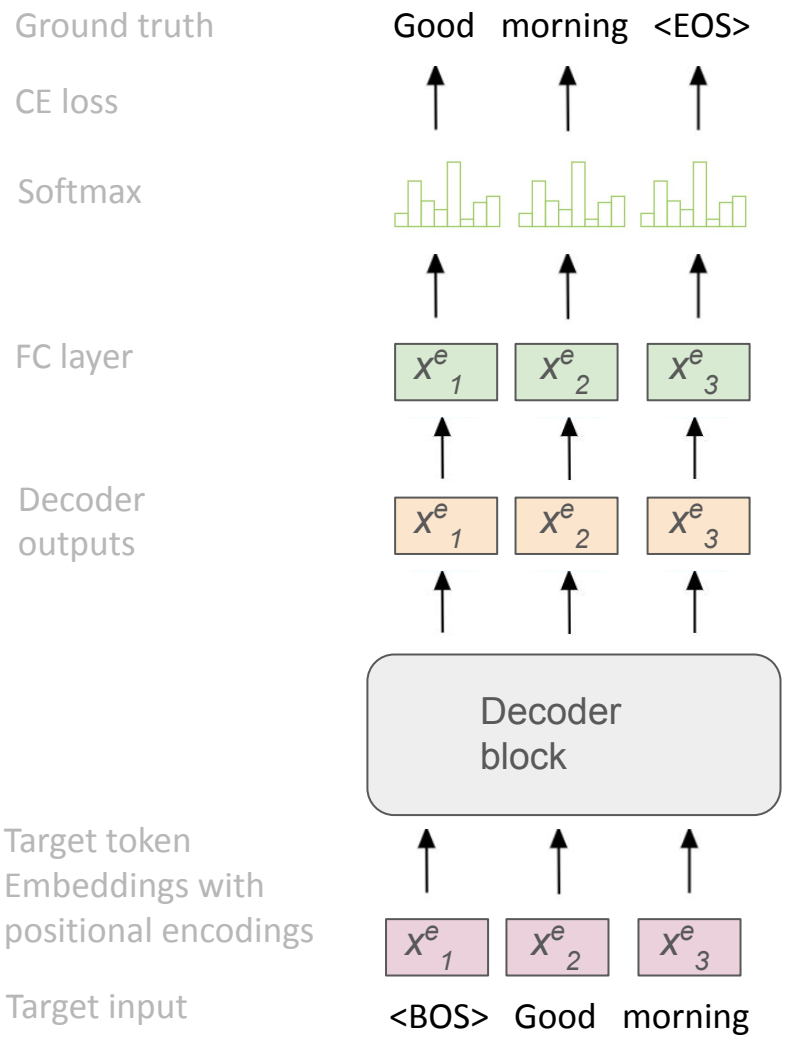

Во время инференса decoder генерирует выходную последовательности ***авторерессивно***

Transformer

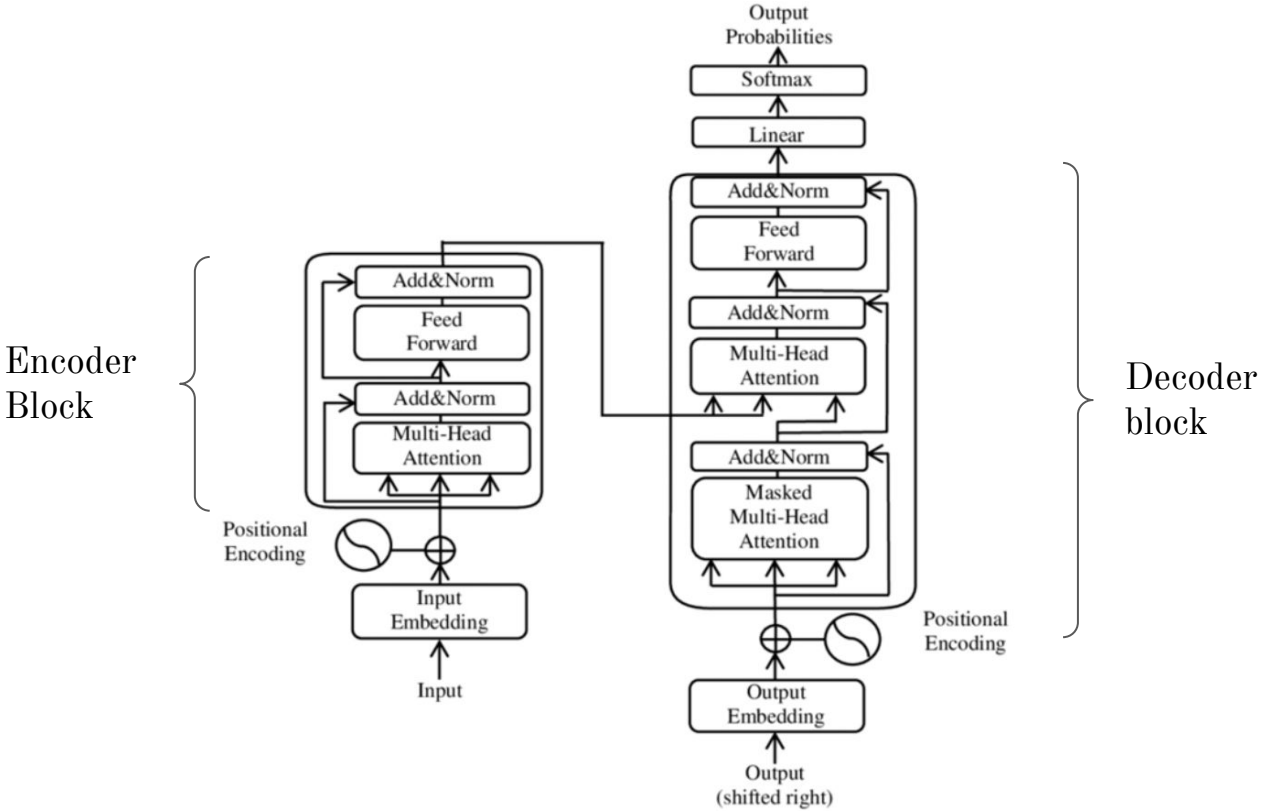

Masked Self-Attention

Что было в Encoder блоке:

Encoder

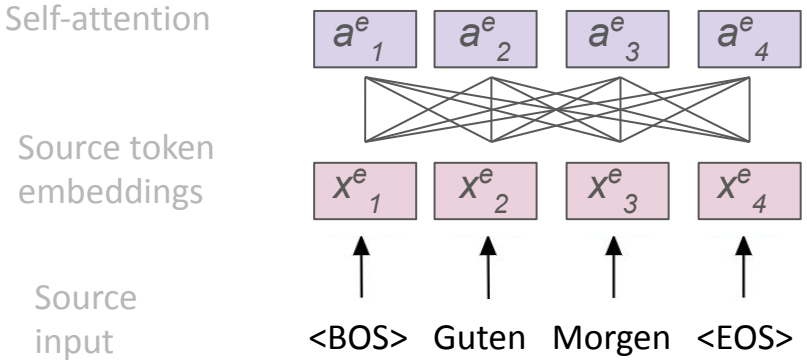

Masked Self-Attention

Во время обучения эмбеддинги x^e_i не могут брать информацию из “будущих” токенов

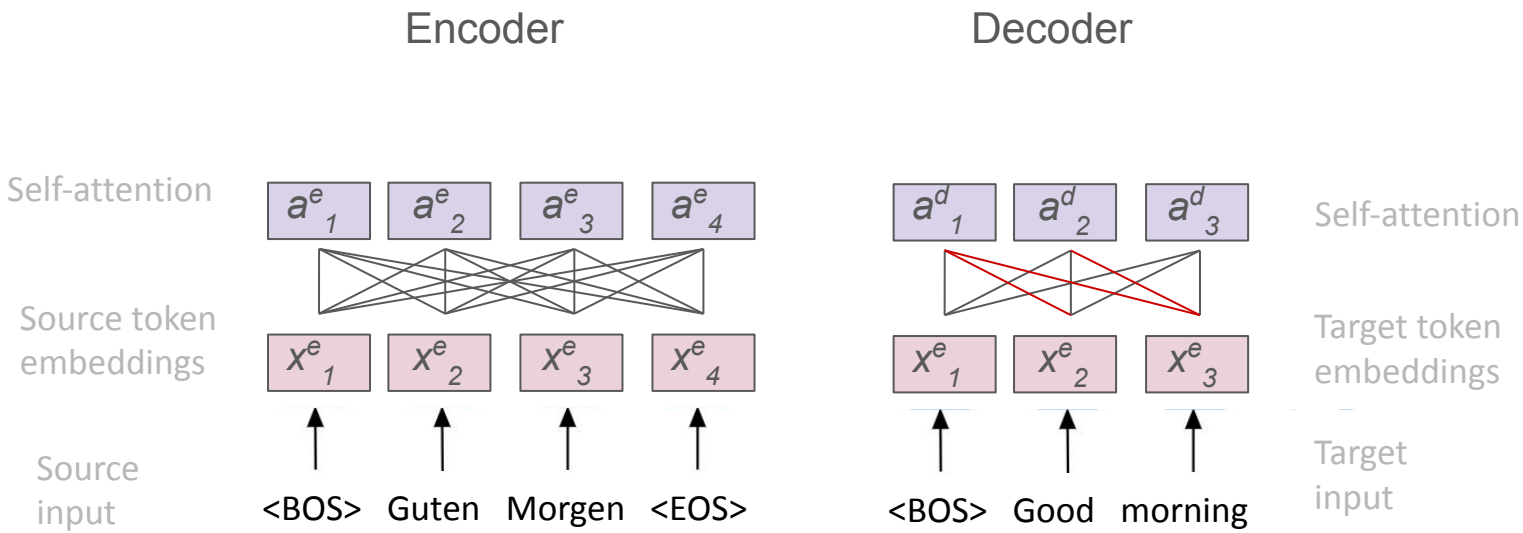

Masked Self-Attention

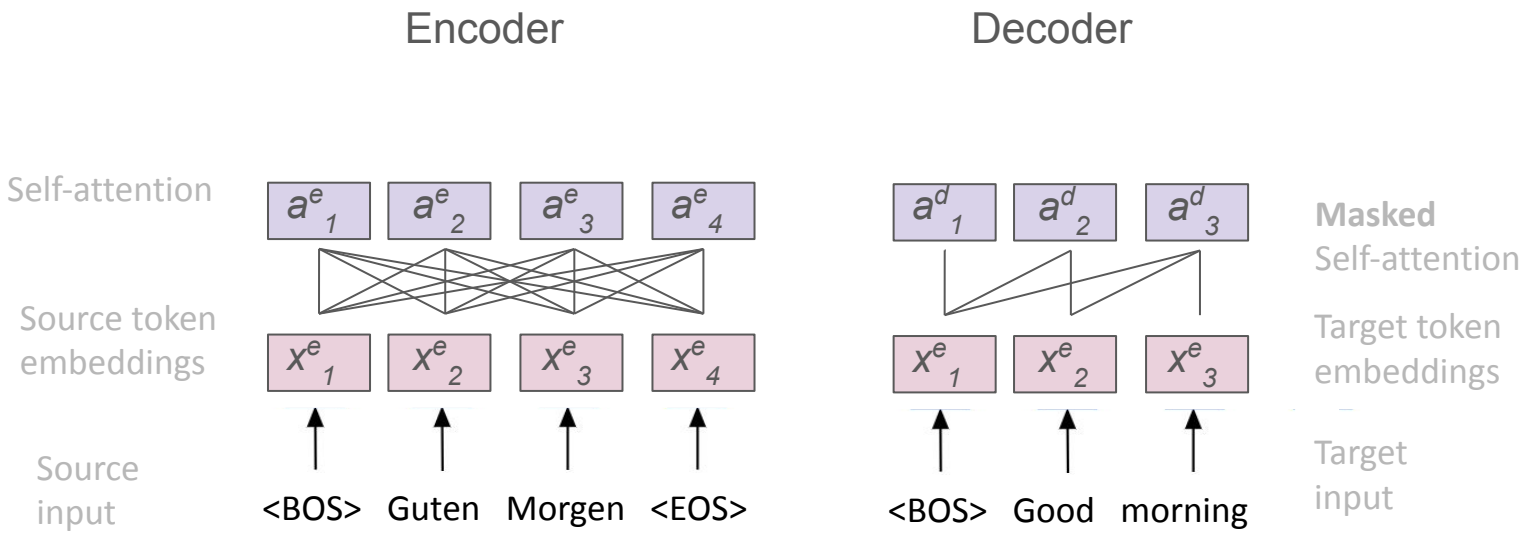

Transformer

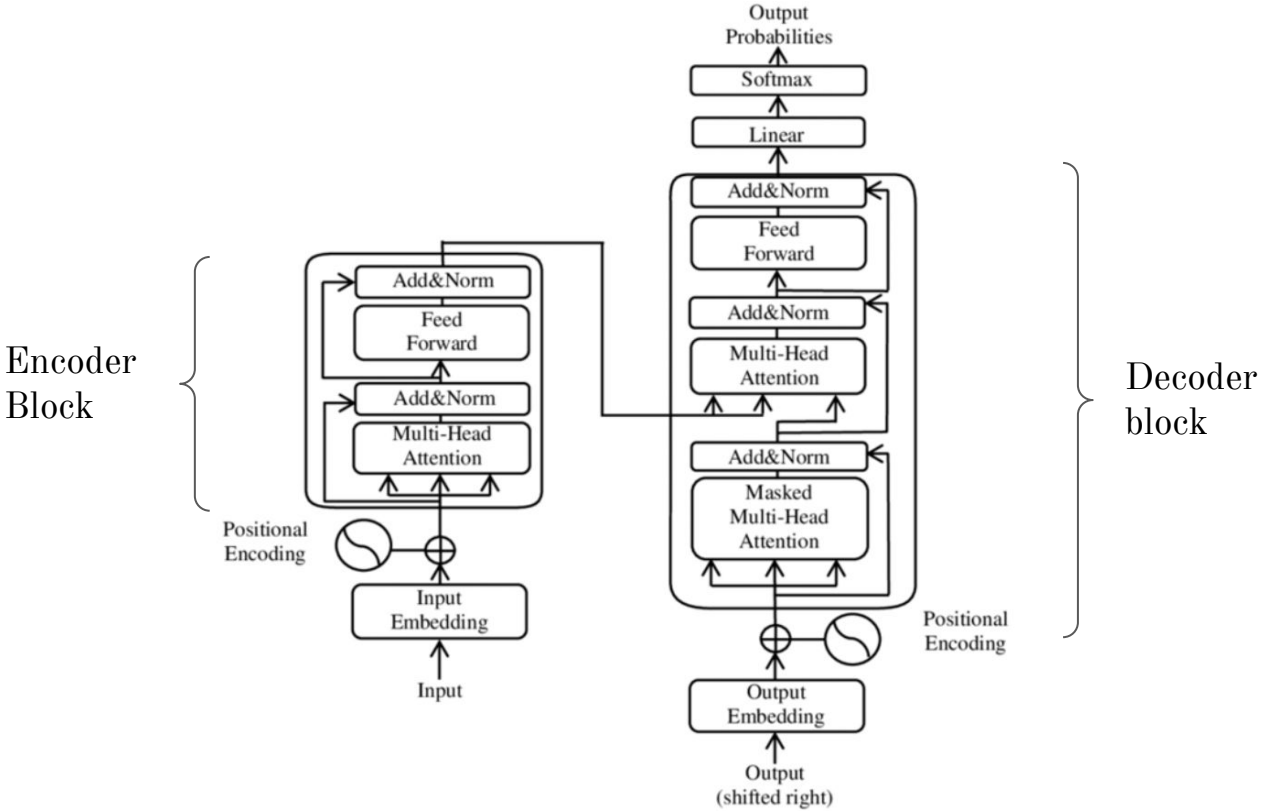

Cross-Attention

Каждый эмбеддинг декодера соберет информацию из эмбеддингов энкодера

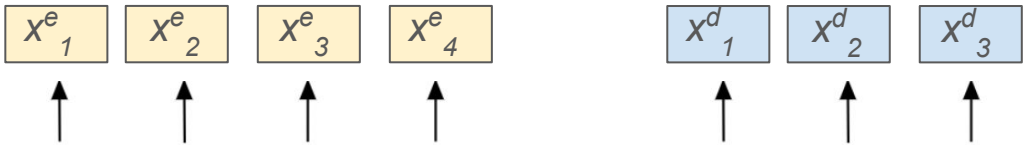

Финальные выходы энкодера

Выходы слоя декодера

$$a_1^{ed} = \sum_{i=1}^{4} w_{1i} x_1^d$$

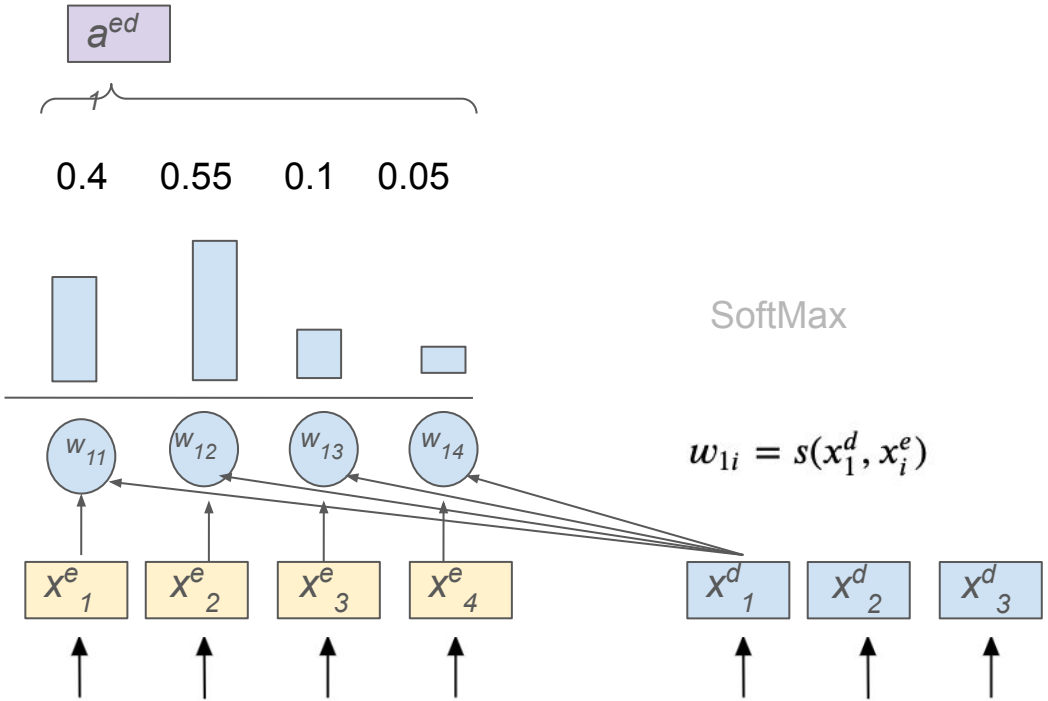

$$w_{1i} = s(x_1^d, x_i^e)$$

Финальные выходы энкодера

Выходы слоя декодера

$$a_2^{ed} = \sum_{i=1}^{4} w_{2i} x_2^d$$

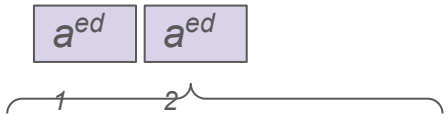

0.1 0.15 0.5 0.25

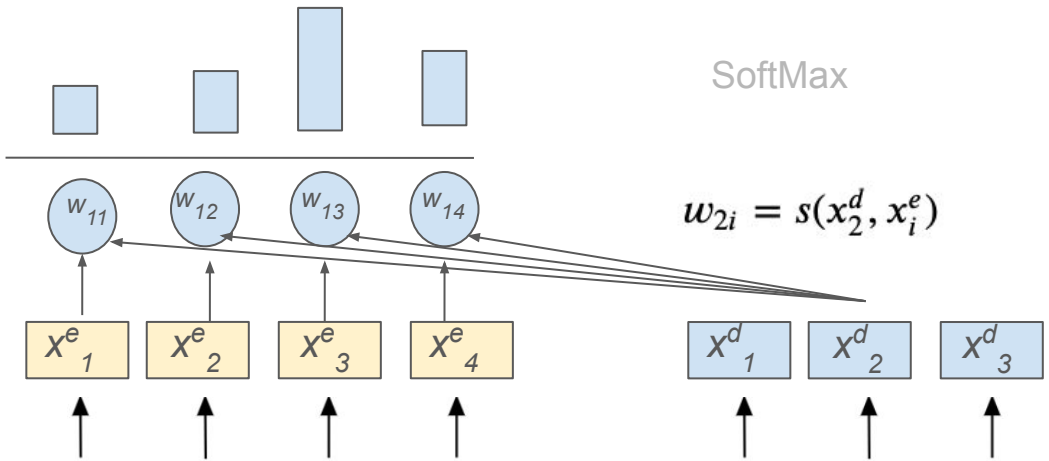

$$w_{2i} = s(x_2^d, x_i^e)$$

Финальные выходы энкодера

Выходы слоя декодера

$$a_3^{ed} = \sum_{i=1}^{4} w_{3i} x_3^d$$

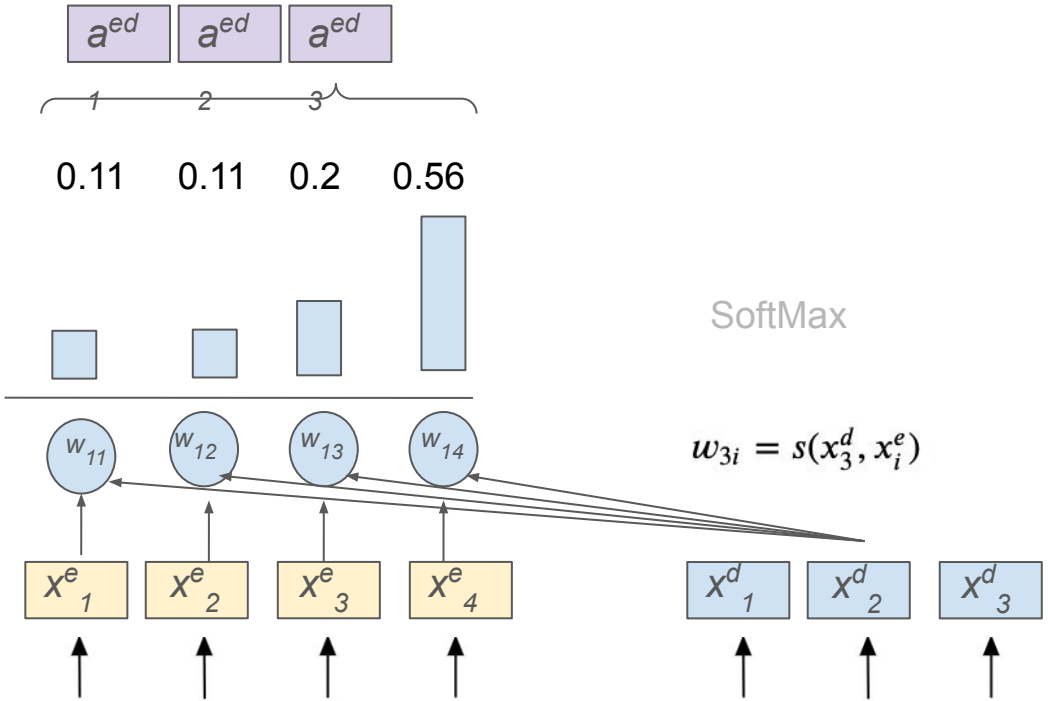

Финальные выходы энкодера

Выходы слоя декодера

Векторы cross-attention

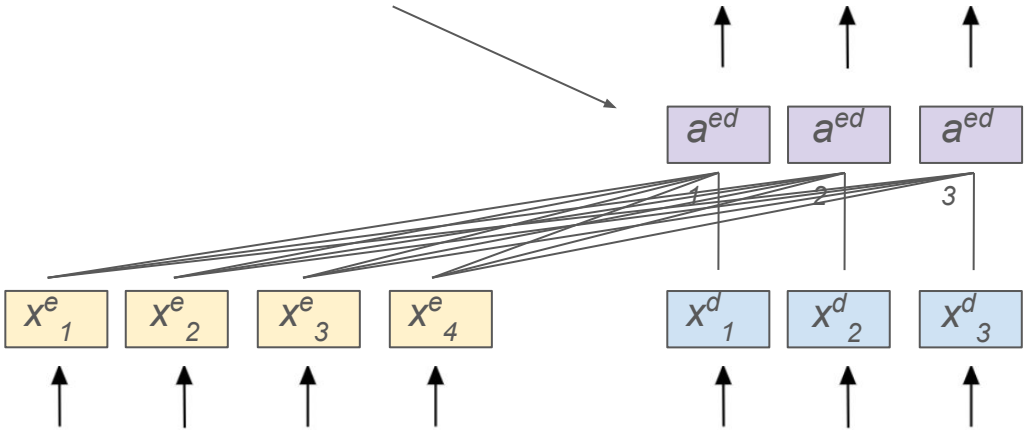

Финальные выходы энкодера

Выходы слоя декодера

Decoder block

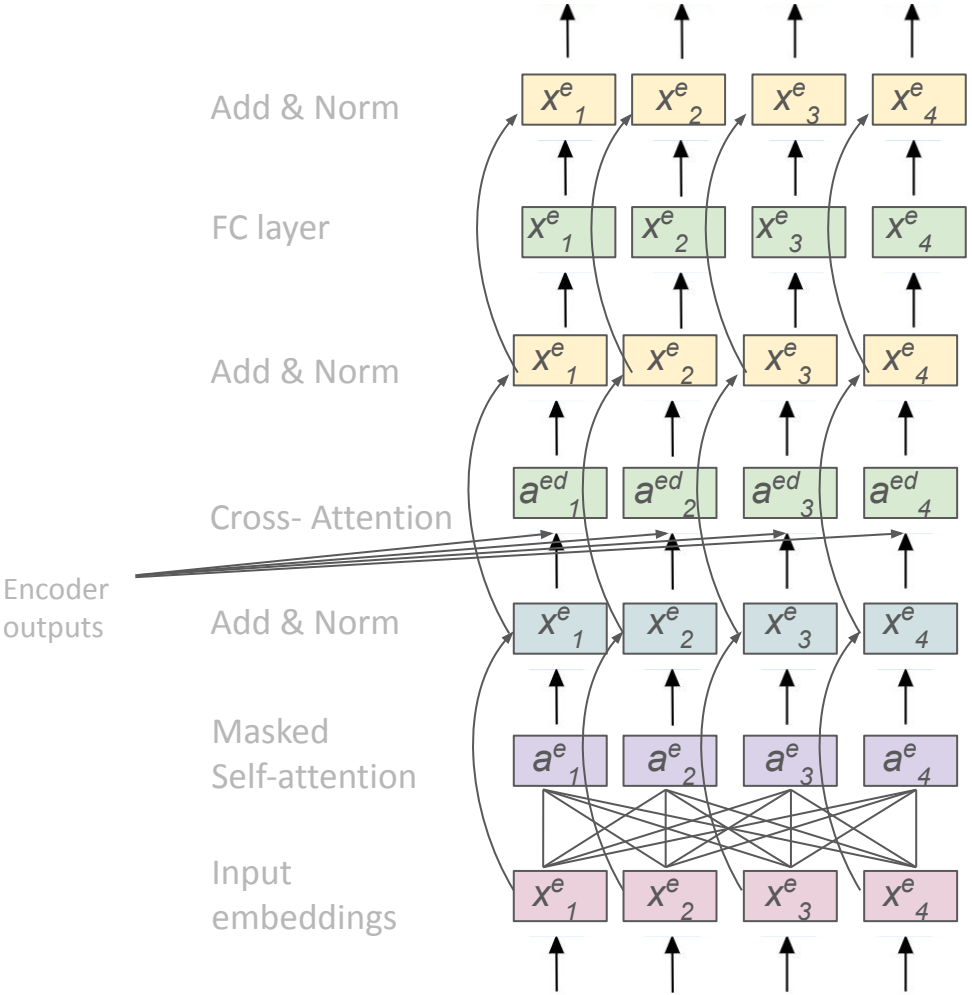

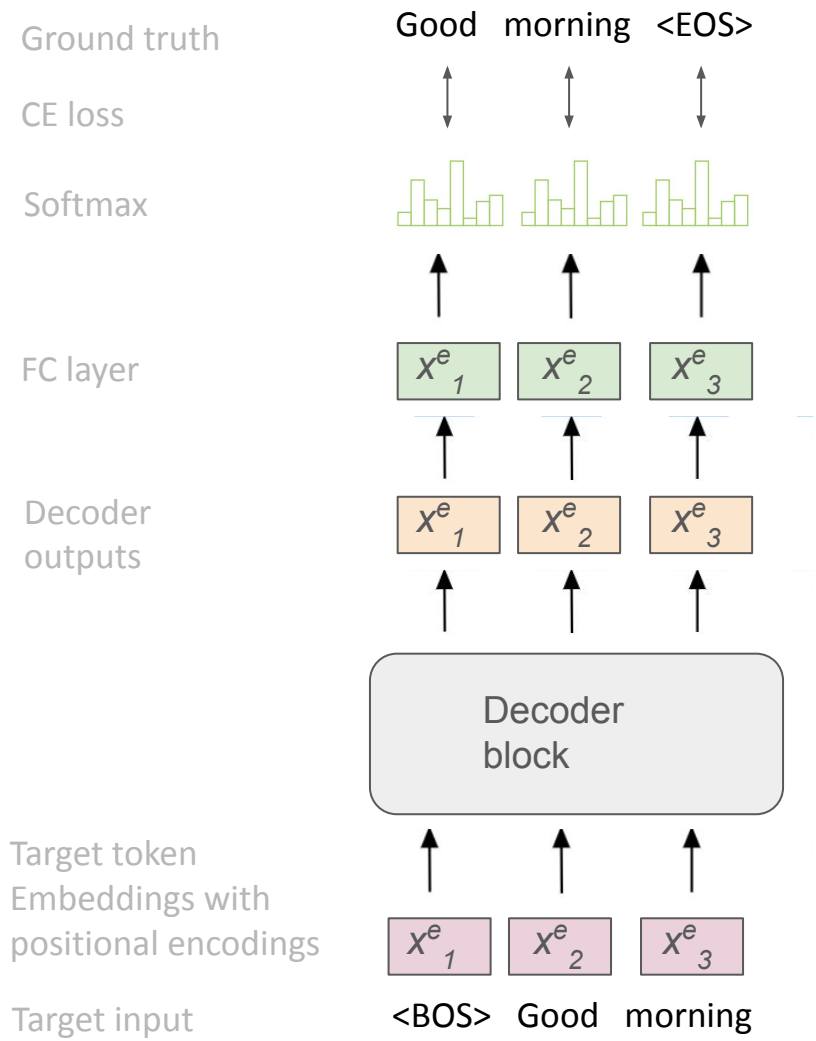
Ground truth
Good morning <EOS>
CE loss
Softmax
FC layer
x^e_1 x^e_2 x^e_3
Decoder outputs
x^e_1 x^e_2 x^e_3
Decoder block
Target token Embeddings with positional encodings
x^e_1 x^e_2 x^e_3
Target input
<BOS> Good morning

Transformer Decoc

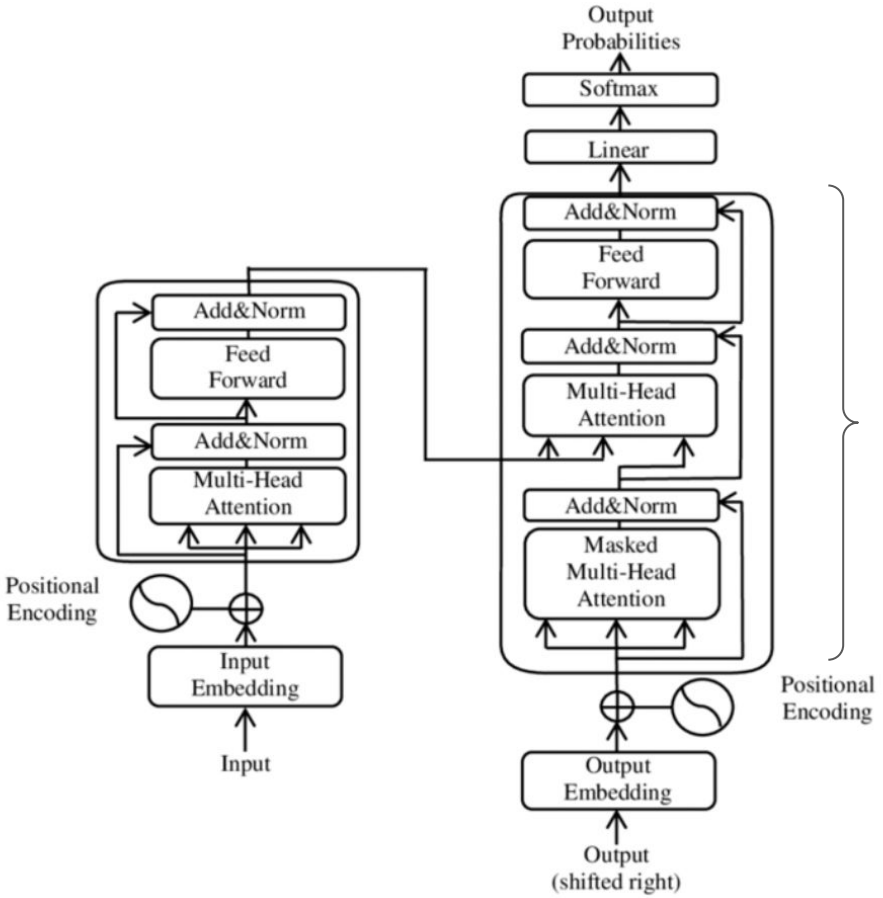

QKV Attention

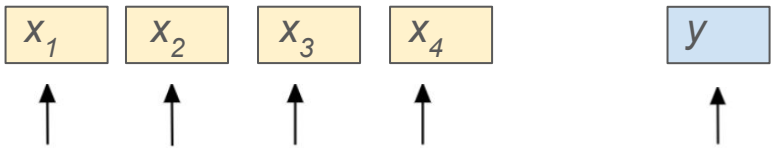

QKV Attention

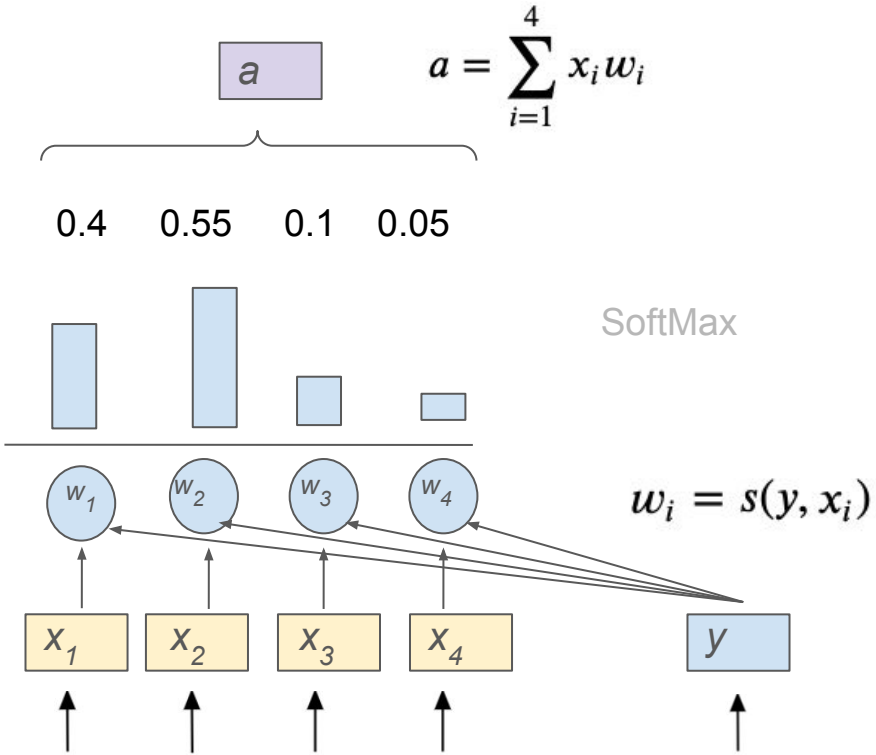

QKV Attention

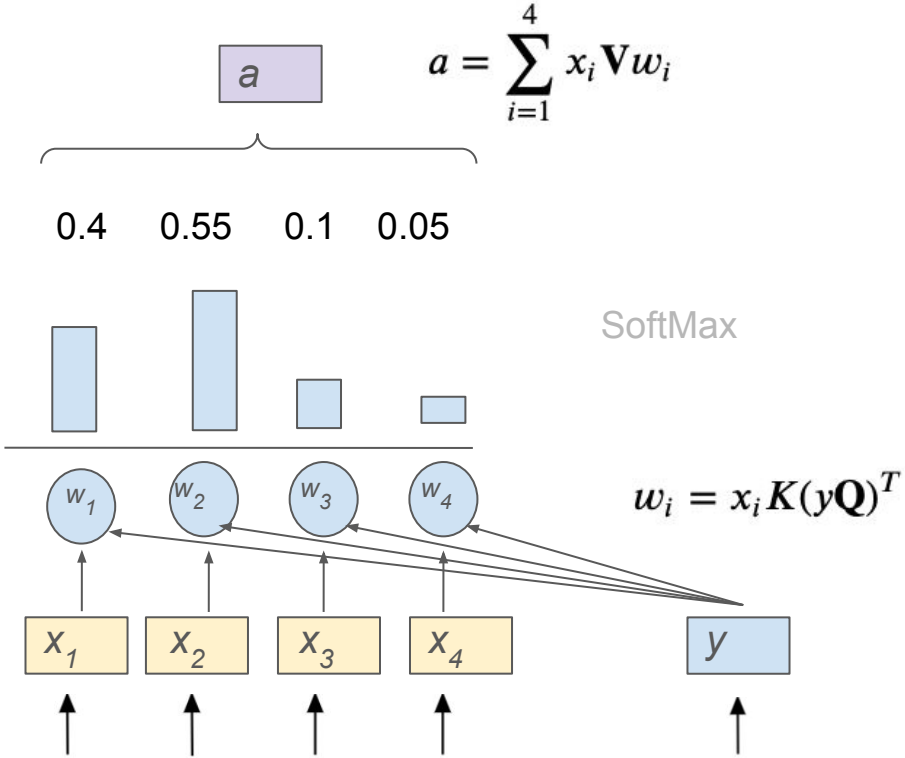

У QKV Attention 3 обучаемые матрицы::

- Q_{dxm} (query)
- K_{dxm} (key)
- V_{dxm}(value)

Здесь:

- D — длина эмбеддингов;
- M можно выбирать любым

QKV Attention в векторной форме:

$$w = softmax\left(\frac{xK(yQ)^T}{\sqrt{m}}\right)$$

$$a = w(xV)$$

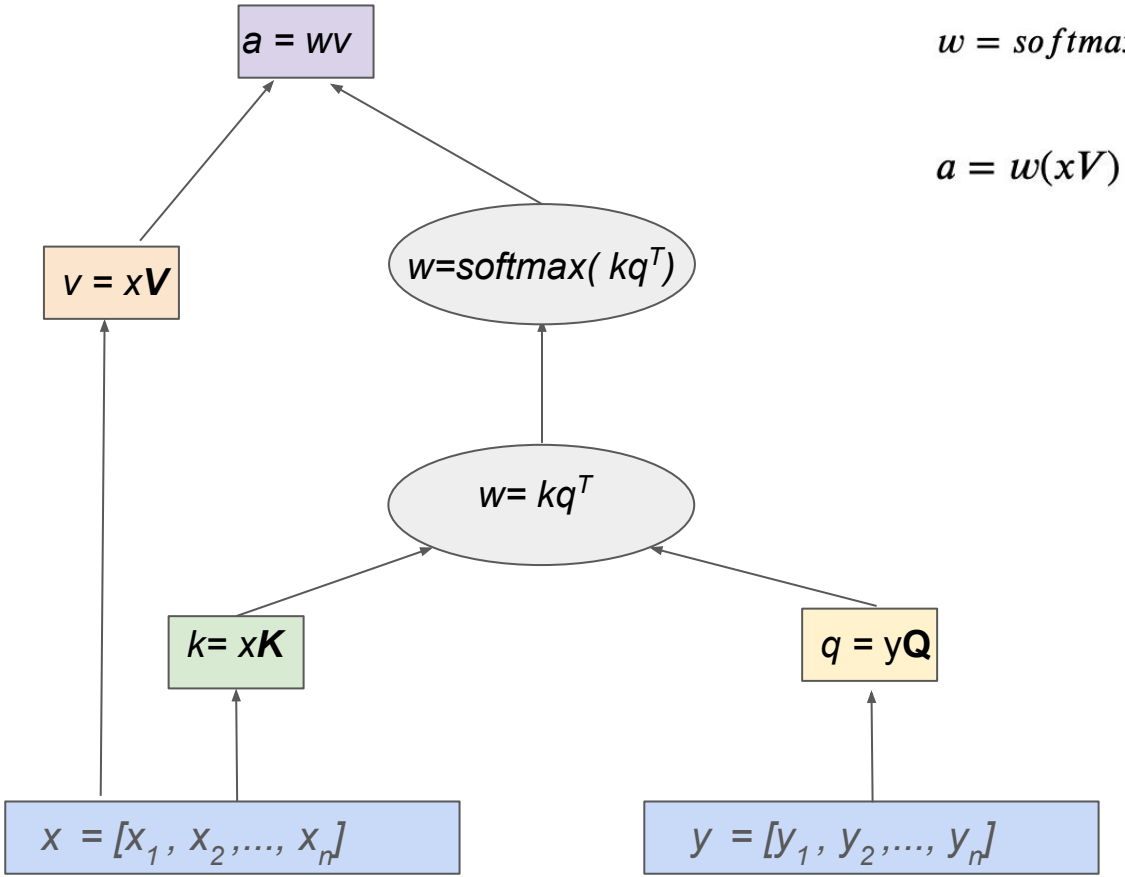

Transformer

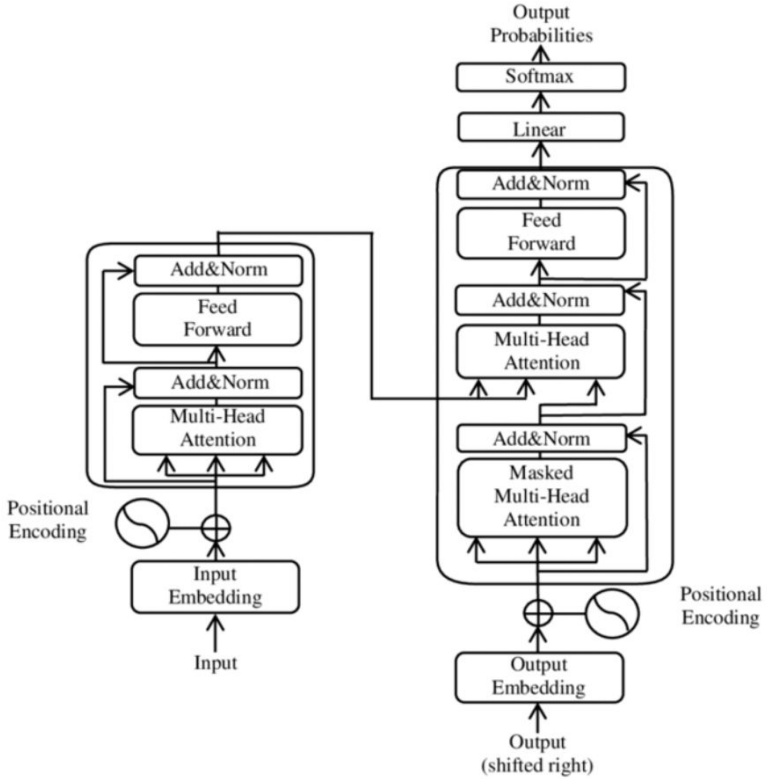

Итоги видео

В этом видео мы:

- Детально разобрали устройство decoder блока Transformer;
- Собрали полную архитектуру Transformer;
- Узнали, как работает QKV Attention.

Итоги видео

- Устройство
- Transformer blocks structures:
  - LayerNorm;
  - Self-Attention
  - Masked Self-Attention
  - Cross-Attention
  - QKV Attention